



同濟大學

TONGJI UNIVERSITY

硕士学位论文

(专业学位)

一种基于 P2P 网络的信息自主流动机制的研究

姓 名： 先毅昆

学 号： 1236191

所在院系： 软件学院

职业类型：

专业领域： 软件工程

指导教师： 张晨曦

副指导教师： 奚自立

二〇一五年三月



同濟大學  
TONGJI UNIVERSITY

A dissertation submitted to  
Tongji University in conformity with the requirements for  
the degree of Master of Computer Science

## **Study of the Mechanism of Information Spontaneous Propagation on P2P Network**

Candidate: Yikun Xian  
Student Number: 1236191  
School/Department: School of Software Engineering  
Discipline:  
Major: Software Engineering  
Supervisor: Chenxi Zhang

March, 2015

一种基于 P2P 网络的信息自主流动机制的研究 先毅昆 同济大学

## 学位论文版权使用授权书

本人完全了解同济大学关于收集、保存、使用学位论文的规定，同意如下各项内容：按照学校要求提交学位论文的印刷本和电子版；学校有权保存学位论文的印刷本和电子版，并采用影印、缩印、扫描、数字化或其它手段保存论文；学校有权提供目录检索以及提供本学位论文全文或者部分的阅览服务；学校有权按有关规定向国家有关部门或者机构送交论文的复印件和电子版；在不以赢利为目的的前提下，学校可以适当复制论文的部分或全部内容用于学术活动。

学位论文作者签名：

年      月      日

## 同济大学学位论文原创性声明

本人郑重声明: 所呈交的学位论文, 是本人在导师指导下, 进行研究工作所取得的成果。除文中已经注明引用的内容外, 本学位论文的研究成果不包含任何他人创作的、已公开发表或者没有公开发表的作品的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体, 均已在文中以明确方式标明。本学位论文原创性声明的法律责任由本人承担。

学位论文作者签名:

年      月      日

## 摘 要

应概括地反映出本论文的主要内容,包括工作目的、研究方法、研究成果和结论,要突出本论文的创造性成果。摘要力求语言精炼准确,硕士学位论文建议1000字以内,博士学位论文建议3000字以内。摘要中不要出现图片、图表、表格或其他插图材料。

学位论文原则上应用汉语撰写,对于用汉语授课并享受中国政府奖学金的博士硕士留学研究生,学位论文如用英语(德语、法语)撰写,硕士学位论文不少于3000汉字摘要,博士学位论文不少于5000汉字摘要;对于其他情况(含用英语授课)的博士硕士留学研究生,学位论文如用英语(德语、法语)撰写,可不要求撰写汉语摘要,但必须有英语摘要。

关键词是为了便于文献索引和检索工作,从论文中选取出来用以表示全文主题内容信息的单词或术语,摘要内容后另起一行标明,一般35个,之间用“,”分开。

**关键词:** 关键字, 摘要

## **Abstract**

First Paragraph

SecondParagraph

Tongji University, located in Shanghai, has more than 50,000 students and 8,000 staff members (as of 1 September 2007). It offers degree programs at both undergraduate and postgraduate levels. Established in 1907 by the German government together with German physicians in Shanghai, Tongji is one of the oldest and most prestigious universities in China. Among its various departments it is especially highly ranked in engineering, among which its architecture, urban planning, and civil engineering departments have consistently ranked first in China for decades, and its automotive engineering, oceanography, environmental science, software engineering, German language departments are also ones of the best domestically.

**Kew Words:** English Keywords, Abstract

## Contents

第 1 章 绪论 .....	1
1.1 选题背景 .....	1
1.2 研究意义与应用价值 .....	3
1.3 国内外研究现状 .....	5
1.3.1 文本挖掘相关工作 .....	6
1.3.2 用户兴趣挖掘相关工作 .....	9
1.3.3 P2P 网络路由搜索相关工作 .....	11
1.4 本文内容安排 .....	13
第 2 章 基于 P2P 网络的信息自主流动机制的方案概述 .....	15
2.1 文本信息分析与建模 .....	15
2.2 用户兴趣表示与匹配 .....	19
2.3 P2P 网络构建与发现 .....	22
2.4 小结 .....	25
第 3 章 互联网文本信息分析与建模的研究 .....	26
3.1 长文本信息的分析与建模方法 .....	26
3.1.1 基于相似度的长文本主题识别算法 .....	26
3.1.2 基于标签的主题分析技术 .....	27
3.1.3 基于标签的长文本主题识别算法 .....	29
3.2 短文本信息的分析与建模方法 .....	31
3.2.1 视频精彩镜头的抽取问题 .....	31
3.2.2 弹幕短文本的特征 .....	33
3.2.3 视频小段的表示和相似度 .....	33
3.3 文本网的分析与建模方法 .....	35
3.4 文本流的分析与建模方法 .....	35
3.5 小结 .....	35
第 4 章 用户兴趣表示与匹配的研究 .....	36
4.1 分类兴趣树的构建与更新方法 .....	36



4.2 动态兴趣树的构建与更新方法 .....	36
4.3 用户兴趣的自适应学习方法 .....	36
4.4 小结 .....	36
第 5 章 基于 P2P 网络的信息自主流动机制的研究 .....	37
5.1 用户兴趣覆盖网络的构建 .....	37
5.2 兴趣覆盖网络的资源传播 .....	37
5.3 兴趣覆盖网络拓扑结构的更新 .....	37
5.4 小结 .....	37
第 6 章 实验分析与结果分析 .....	38
6.1 小结 .....	38
第 7 章 原型系统设计与实现 .....	39
7.1 小结 .....	39
第 8 章 结论与展望 .....	40
致谢 .....	41
参考文献 .....	42
个人简历、在读期间发表的学术论文与研究成果 .....	48

## 第1章 绪论

### 1.1 选题背景

互联网技术的蓬勃发展在很大程度上给人们的生活带来了越来越多的便利，人们在逐渐适应网络这样的平台的同时，也更倾向于甚至依赖在网络平台上完成生活中的各种事情，可以说，网络对于人们的重要性已经几乎等同于空气、水和食物。按照网络平台的功能来划分，门户网站（新浪、搜狐等）是新闻实事评论发布的主要渠道，社交网站（微博、人人等）是人们分享个人想法和心情的首选，博客系统（新浪博客、百度空间等）是人们发表和传达思想和经验的主要平台，以及一些新新涌现的图片和视频等多媒体资源分享平台（优酷土豆、POCO等）大大丰富了人们的娱乐生活。此外，鉴于国内发达的物流行业，各大电子商务平台（淘宝、京东等）也使得不用出门就能购物成为了现实。按照网络平台资源的载体来划分，包括文本、图片、音乐和视频几大类，其中文本无疑是整个互联网资源的主体，无论是传统的新闻、博客、评论、说明，还是新发展的弹幕视频网站（Acfun<sup>1</sup>、Bilibili<sup>2</sup>等），都是由很多文本信息组成的。按照网络平台的用户参与角度来划分，可以将用户角色分为两种：信息发布者和信息获取者。以程序员为例，当他需要学习一项新技术时，往往会通过搜索引擎寻找一些与该技术相关的教学经验文章，从而使自己尽快掌握该项技术。等对该技术数量掌握之后，往往又会通过写技术博客的方式记录下他的学习历程和使用中的经验之谈，以供他人参考。同时，该用户还肯定拥有其他多个兴趣爱好，比如他可以与网上其他用户分享旅游游记、摄影作品等等。

虽然这些网站系统在功能上、信息载体上或是用户参与方式上都截然不同，但是宏观来看他们都存在一个共同的问题：信息孤岛现象。如图 1.1所示，当这些网站发展越来越多之时，各个网站之间信息不流通的问题也日渐明显，每个网站独立发展，出于安全性等方面的考虑，其资源和用户的数据并不能实现跨平台共享，从而使得每个网站成为一座座信息孤岛。

举例来说，当用户作为信息获取者时，虽然每个网站可以为本平台上的用户提供很好的用户体验，通过数据挖掘等技术发现用户的兴趣，为其推荐有潜在需求的信息，但是不同网站之间的用户兴趣不能共享，导致兴趣推荐的不准确。当用户作为信息发布者时，其操作会更加繁琐，他往往需要打开多个网站重复几乎相同的操作来发布同样的内容，最明显的证据就是同时使用微信、微博和人人的用户需要在三个平台上重复三次操作完成发布。当这些网站越来越多的时候，问题也随之而来，即用户可能需要打开很多个独立的网站来完成一系列类似的事情。比如，先在新闻网站上浏览最新发生的时事，接着在摄影网站上发布新照

<sup>1</sup><http://www.acfun.tv/>

<sup>2</sup><http://www.bilibili.com/>




图 1.1: 互联网平台的信息孤岛现象

片，然后在社交网站上浏览好友更新的状态，最后在电商网站上购买一些商品等等。换句话说，用户是单向地去寻找想要的信息，这其中无疑包含了一些不必要的重复操作。退一步来说，即使存在某些用户只在社交网站上浏览信息，很少接触其它网站，也会有一些重复操作的问题。因为该用户的好友很有可能是分散地活跃于各个不同的社交网站平台(微博、人人网等)，而且每个平台发布的信息肯定有所不同，所以该用户仍然需要逐个登录各个网站后才能浏览到各个用户的信息。再退一步说，即便现在已经有些软件把所有社交网站整合成一个统一接口，让用户只需一次登录就能同时访问多个平台，用户仍然会遇到信息冗余的问题，比如重复的新闻、不感兴趣的推荐等等。

为了解决上述问题，现在设想有这样一个智能系统：每当用户打开系统时，系统会自动推送今天的时事新闻、其好友最近更新的状态、感兴趣或者正在促销的商品，以及一些根据用户偏好过滤的信息。此外，他也可以在系统上发布自己的信息给他的好友，甚至给那些对他信息感兴趣的陌生人。虽然，实现这样一个系统的工作量和难度是巨大的，但仔细观察后可以发现这样一个重要的规律：即用户希望所有的信息能够在整个互联网上智能地自主流动，在用户单方面寻找信息的同时，让信息也能自主地流向符合特定需求的用户。

从抽象层面来看，要实现这样一套信息自主流动的机制，传统的集中式计算模式已经不再适用。如图 1.2所示，这里每个用户均看作一个独立的节点，所有

的节点整合在一起就形成一个巨大的 P2P 网络。其中，每个节点既充当服务器用于分发信息，也充当客户端用于接收信息，并且由某个节点发出的信息在其它节点间传播的时候会自主流动，寻找潜在的、匹配的节点。简单来说，要使信息能够自主流动，就要攻克这几方面的难点：

- 资源信息描述与匹配：互联网资源普遍呈现出半结构化或非结构化的特征，以普通的新闻或者博客为例，除了作者、标题、时间等结构化信息，正文纯文本都是典型的非结构数据。因此，如何从这些非结构化的文本信息中提取出有用的特征、并用这些特征来衡量这些文本之间的相关性是本文重要研究内容。
- 用户兴趣挖掘与关联：用户的兴趣可以从其发布和查看的信息中反映出来，基于上述对资源信息的描述模型，可以训练出某一时刻或者某一时段内的用户兴趣。但是，由于用户兴趣可能会随着时间的推移而不断变化，并且在同一时刻可能同时存在长期兴趣和短期兴趣。因此，这部分需要基于资源模型来解决用户兴趣随时间变化的问题。
- P2P 网络路由与搜索：从整个网络结构来看，在初始状态下各个用户节点之间的关系仅仅为物理意义上的距离关系，换句话说，节点与节点之间的边的权重不能代表用户与用户之间兴趣的相似度，从而也就导致每个节点上的信息不能自由传播。因此，这部分需要借助用户兴趣模型，通过 P2P 网络的路由搜索算法来寻找潜在的相似节点，最后构成某一时间段内的稳定结构。

## 1.2 研究意义与应用价值

对于上述提出的信息孤岛现象是主要由目前网站之间相互独立而导致的，这些中心化结构的独立网站架构存在以下几个问题：

- 从资源传播的角度来看，每个网站的数据都仅仅在一个局部范围内可用，但是用户却要在多个这样的局部范围内同时使用多个网站。虽然对于每个网站可以维护相对较好的资源整合和管理，但是对于属于用户的资源的传播带来了很大的阻碍。
- 从计算资源的角度来看，每个独立的传统 B/S 架构的网站通常由背后的一套计算群组来支撑，当网络流量十分巨大的时候，服务器的硬件和软件性能决定了系统平台可承受的最大程度。而在用户这边的客户端的 I/O 消耗相对小很多，但是大量客户端的请求对于服务器是一个不小的考验，从而导致了服务器成为整个系统的计算瓶颈。

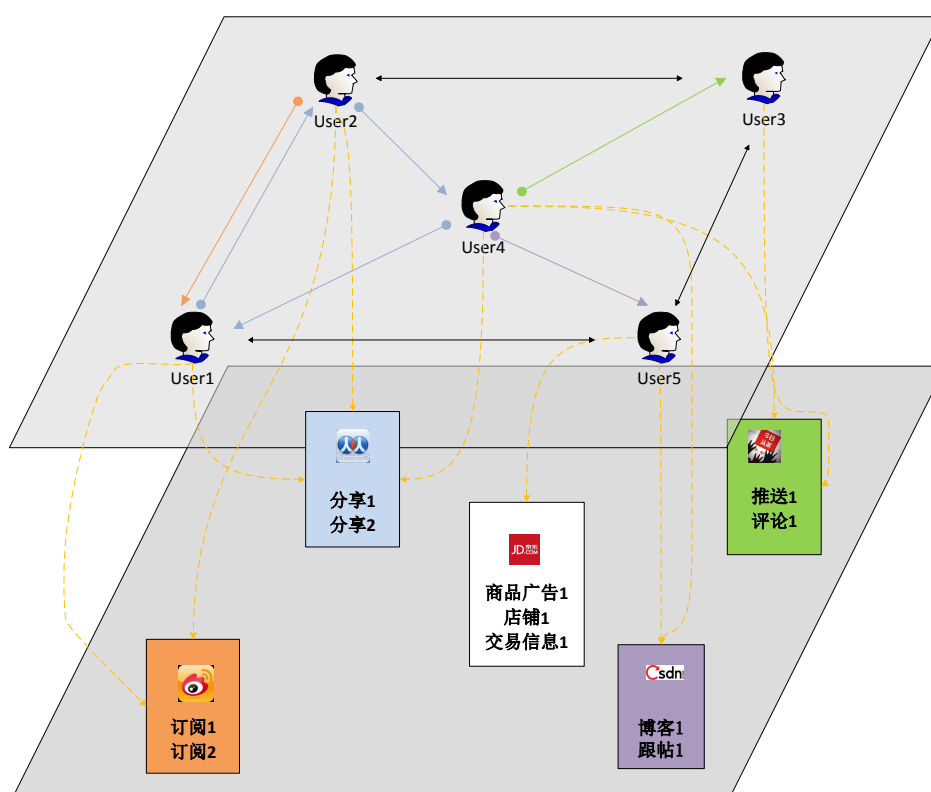


图 1.2: 一种基于 P2P 网络的智能系统解决方案

- 从隐私安全的角度来看，目前网站的数据均由平台自己的数据库进行维护，对于数据泄露成为重大隐患之一，即使网站的安全性是非出色，用户也会担心其数据是否会被第三方利用于商业用途。
- 从拓扑架构的角度来看，用户与网站系统组成了中心化的拓扑结构，该结构不利之处在于当网站服务器宕机或者网络中断的时候，所有用户均无法访问该系统，这就使得网站系统的备份机制与主从切换机制十分完善，而对于大部分初创公司的流量有限和资金不足等特征是一个很大的考验。

与中心化结构网站架构不同，在基于 P2P 网络架构中，每个节点都可以既可以充当服务器为其它节点提供资源，也可以作为客户端向其它节点获取资源。综合来说，P2P 网络的应用具有以下几大优点 [1]:

- 非中心化（Decentralization）：在 P2P 网络中，节点之间的通信无需经过中心服务器，因此大大降低了服务器因为计算资源问题而导致的性能瓶颈。同时，网络中的信息资源完全存储在各个节点中，信息的交互完全在节点之间进行。
- 可扩展性（Scalability）：由于 P2P 网络中的每个节点可以看做服务提供者，

所以每当有新的节点加入时,相当于扩充了整个网络的服务能力和资源,相反用户节点也可以随时退出,十分的灵活。以网络下载资源为例,普通 C/S 模式的计算下载通道的传输能力基本依赖于服务器的带宽,当用户一旦很多的时候,下载速度往往会受到很大的影响,但是在 P2P 网络中却恰恰相反,更多的节点请求意味着有更多的资源提供者,从而下载速度也更快。

- **健壮性 (Robustness):** 与中心化架构模式不同, P2P 网络不会因为某一个节点退出而在很大程度上影响网络的正常运行,相反只有很小的一部分影响。结构良好的 P2P 网络一旦在某几个节点发生异常的时候会自动调整拓扑结构,从而保证整个网络的连通性。
- **安全性 (Security):** 传统集中式的计算模式在通信上往往需要经过中心服务器,也就是说用户的数据信息会全部经过这些服务器,因此只要在这些为数不多的服务器上动些手脚,用户隐私就会被泄露。但是,在 P2P 网络上则不同,信息传输不会经过某些特定的节点,并且还可以与特定有需求的目标节点建立连接,从而在很大程度上提升了匿名通信的可靠性以及灵活性。
- **负载均衡 (Load-Balance):** 根据上文所述, P2P 网络下的用户节点既能充当信息发布者的角色,也可以作为信息接受者的角色,所以在计算资源和存储资源的分布十分均匀。同时,对于信息接受者来说,其可以向计算资源空闲的节点请求资源,而不用排队等待那些繁忙的节点直到任务完成。

基于上述有点,本文首先建立一套用于描述互联网信息和用户行为偏好的模型,旨在将这些具体的信息和用户行为偏好上升到抽象层面,剥离出一个统一的输入输出接口。对于那些专注于复杂的数据分析和建模工作的模块,该接口起到了整合的作用。而且,在此之后,也可以展开专门基于该描述模型的信息与用户匹配算法的研究。其次,根据上述信息描述模型与用户行为偏好模型的特点,从拓扑结构,通信机制等方面入手,建立一套合适的分布式架构(如 P2P 的计算模式),并利用上述的匹配算法,研究由各个节点组成的覆盖网络间的信息自主流动的机制。最后,将上述两项内容结合在一起,实现一套完整的信息自主流动的原型系统。

### 1.3 国内外研究现状

从目前的科学研究和商业应用方面来看,还没有关于一套基于 P2P 网络的信息自主流动机制的相关工作。因此,这部分将从文本信息挖掘、用户兴趣关联以及 P2P 网络搜索等三方面来具体展开阐明已有的研究工作。

### 1.3.1 文本挖掘相关工作

在文本信息挖掘方面,由于当今的硬件和软件技术在各方面都有大幅度提高,产生了大量的不同类型的数据资源 [2],特别是纯文本的数据。这些文本大多来自于社交网络、新闻博客等网站,内容形式对于人们来说也是十分的丰富。但是这对机器来说却没有那么容易识别,因此需要设计一系列的算法来从这些文本数据中找出一些模式和规律,从而让机器更好地利用这些数据为人们创造更大的价值。结构化数据 (Structured) 通常可以存储在各类数据库中,但是纯文本数据却因为它的半结构化 (Semi-structured) 或者非结构化 (Unstructured) 特性从而只能有通过搜索引擎等技术才能进行索引和查找 [3]。搜索引擎是信息检索 (IR) 中的一种方式,其作用是方便用户直接通过输入关键词找到内容相关的文档集合,其目标是如何通过有效和高效的方法是检索的结果更加精确,涉及的研究领域包括文本聚类、文本分类、文本概括、推荐系统等 [4, 5, 6]。但是,在本文中,除了这些信息检索基本的需求,更重要的是从文本中挖掘出重要的特征和模式,将原本非结构化的数据量化成半结构化数据,并且这种量化过程更多地从用户兴趣这点切入的。针对这个要点,文本挖掘技术一般可以分为以下几大类:

#### 1.3.1.1 文本抽取

文本抽取 (Text Extraction) 主要是从半结构化或结构化的纯文本里找出结构化信息,涉及了自然语言处理 (NLP),信息检索和 Web 挖掘 (Web Mining) 等领域的技术。该研究最基本的两大工作是: a) 命名实体检测 (NER),包括找出文本中的人物、地点、组织等等;和 b) 关系抽取 (Relation Extraction),主要包括名字之间的地理位置关系、人物关系、动作执行关系等等。

其中,对于命名实体检测问题,主要包括基于规则的方法 [7, 8] 和基于统计学习的方法,后者有三个十分著名和常用的方法:隐马尔可夫模型 (HMM) [9],这是一个简单且有效的生成模型 (Generative Model),最大熵马尔可夫模型 (MEMM) [10],这是一个判别模型 (Discriminative Model),适合于训练集十分充足的情况,因为它能给出一个更小的预测误差,以及条件随机场 (CRF) [11],该模型是一个基于无向图的判别模型,因此适用于当前状态均受前后影响的情况。

对于关系抽取问题,主要包括基于分类的方法 (Classification-based) [12, 13, 14, 15] 和基于核的方法 (Kernel-based) [16, 17]。其中,分类方法在应用之前需要对文本进行特征提取 (Feature Extraction),比较有用的特征包括实体、词汇、语法和背景知识等。而核方法最常见的场景是先将文本用向量空间模型 (VSM),再进行下一步计算,主要分为基于序列的核方法、基于树的方法和混合核方法,在机器学习中,核函数 (Kernel Function) 是两组向量空间的内积,也可以

看做观测值之间的一种相似度衡量方法，从而观测值不需要显示地映射成向量空间。

总结来说，当前命名实体检测最有效的方法都是基于概率图模型而提出的，典型代表是 MEMM 和 CRF，而关系抽取的方法则是很大程度上基于选取的特征或者定义的核函数，然后再利用分类算法进行解决。可以发现，上述这些主流方法都是有监督方法，但是，随着互联网产生数据的规模不断增大，半监督和无监督方法会更加实用。

### 1.3.1.2 文本摘要

文本摘要 (Text Summarization) 用于从纯文本中识别出重要的内容，包括重要的句子、关键词和主题等。因此根据不同的表示方式，基本方法可以分为主题表示法、标识符表示法、句子表示法。

其中，主题表示法需要首先找出一种主题描述的方式，一般是用主题词，这种词的特性是排除文档中出现频率高以及极少出现的词，然后利用对数似然比检验 (LR Test) 来识别那些能够很具有代表性的单词 [18]。关于单词出现频率的计算方式，最经典的就是 TF-IDF [19]，这种方法一方面计算了单词出现的频率，另一方面也衡量了单词的重要性。再进一步，文献 [20] 提出的潜语义分析 (LSA) 方法则用一种隐含的方式来表示文本中的语义信息，其十分适用于对新闻文本的总结，而且不需要使用第三方的词典数据就能实现。在 LSA 的基础上，更多的基于贝叶斯理论的主题模型被陆续提出，这些模型在主题表示上十分成熟，而且很多已经在工业界广泛使用 [21, 22, 23, 24]。

对于句子粒度的摘要方法，通常是先将相似的句子进行聚类 [25, 26]，其中相似度的计算方式包括简单的余弦相似度 (Cosine Similarity) 等。处于同一类中的句子被认为是某种主题，而有很多句子的类则说明包含了重要的主题，然后从每个这样的类中选取一个句子作为这种主题的代表，组合起来就是对文章的摘要。同时，对于选出来的句子可以用 KL 散度 (KL Divergence) 来进行评分，从而来判断选出来的摘要的好坏。

### 1.3.1.3 文本降维

文本降维 (Dimensionality Reduction) 用于解决文本向量的维度过大的问题，这里主要的方法包括诸如 LSI (Latent Semantic Indexing)、PLSI (Probabilistic Latent Semantic Indexing) 和 LDA (Latent Dirichlet Allocation) [27, 28] 等主题模型，这些模型共同的假设前提是把文档看做词袋模型 (Bag-of-words)，即不关心单词的先后顺序，从而可以更有效更快速地对文本进行处理。

对于主题模型来说，在整个文档集合  $D$  中，共有  $M$  篇文档，词汇表共有  $W$



个不同的词汇，并且假设总共有  $K$  个主题，其中文档和词汇都是已知的，主题为待求的问题。因为已经存在  $D * W$  维的文档-词汇矩阵  $X$ ，通过主题模型以后本质是将该矩阵分解成两个矩阵： $D * K$  维的文档-主题矩阵  $A$ ，和  $K * W$  维的主题-词汇矩阵  $B$ ，即  $X = A * B$ 。在矩阵  $X$  中，每一行表示一篇文章  $d_m$ ，每一列表示一个词汇  $v_i$ ，每个值  $x_{m,i}$  表示该文档具有该词汇的比重，这个比重可以通过正规化后的词频，也可以是 TF-IDF 的值。在矩阵  $A$  中，每一行表示文档  $d_m$ ，每一列表示主题  $z_k$ ，每个值  $a_{m,k}$  表示该文档具有该主题特征的权重，所以文档可以表示为一个关于主题的  $K$  维向量，从而将文档看成一个服从多项分布的随机变量  $\vec{\theta}_m$ 。在矩阵  $C$  中，每一行表示主题  $z_k$ ，每一列表示词汇  $v_i$ ，每个值  $b_{k,i}$  表示该主题中该词汇占有的比重，由此可见，这里的每个主题表示为关于词汇的一个  $W$  维向量，从而主题可以看做一个服从多项分布的随机变量  $\vec{\phi}_k$ 。关于如何求出参数  $\vec{\theta}_m$  和  $\vec{\phi}_k$  将在后文结合本文提出的模型具体详解。

但是诸如 LDA 这类的主题模型还有很多局限性，第一，LDA 推理的方法大致分为两种 Collapsed Gibbs sampling[28] 和 Variational Approximation[27]，但是两者在整个迭代过程中十分耗时，当数据量很大的时候，特别是词汇表的大小  $W$  达到百万级的时候， $\vec{\phi}_k$  的维度十分高，导致计算很慢。因此，基于这个问题，目前已经提出了并行的亦或是分布式的 LDA 算法 [29, 30]，从而应对工业界大规模数据的问题。第二，当文档集随时间变化时，LDA 本身并不能很好适应这个动态的过程，一种方法是引入时间变量重构概率图模型。文献 [20] 通过扩展了时间维度和 LSI 的张量分析从而实现了历史文档的更新。文献 [31, 32] 则在 PLSI 的基础上加上时间维度提出两个全新的主题模型，分别在视频中活动抽取和音乐抽取方面有所作为。David Blei 作为 LDA 的提出者，后来根据时间动态变化这个需求又提出了基于时间演化的主题模型 [33]，很好地解决了这方面的问题。第三，有些文档间会存在关联，比如学术论文间可以以作者和引用上建立连接，在诸多改进方案之中，RTM 模型 (Relational Topic Model) [34] 在 LDA 的基础上联合模拟文档和链接的生成过程，从而很好地解决了文档网络的问题。

总结来说，基于概率图的主题模型是一种很好的文本降维方式，一方面它以统计学中的降维方法为基础，使得可以推理或近似得出隐藏在文档背后的主题是什么，另一方面，它也给出了对主题的一种新的定义，并且基于这种定义使得模型能够很容易地根据不同类型文档的需求来改进。但是一个很重要的问题是如何能够将这些主题模型应用到实际工业界中，因为在性能、效率方面还是有不尽如人意的地方。

### 1.3.2 用户兴趣挖掘相关工作

用户兴趣偏好主要体现在其对文本资源的喜好程度，换句话说，对用户兴趣挖掘的过程类似于对文本挖掘的过程，但是在技术上有所不同。对于用户兴趣的分析主要包括三个方面：用户兴趣的描述方式、用户兴趣挖掘和用户兴趣的匹配。

#### 1.3.2.1 用户兴趣描述

传统的用户兴趣表示方法包括 VSM[35]、兴趣树等层次结构 [36] 以及基于本体构建的描述方式。其中，VSM 是最基本的描述方式，即将用户的兴趣表示成一个向量，每个值表示用户对该兴趣的喜好程度。对于层次结构的兴趣，主要考虑了兴趣之间的相关性问题的，以及兴趣概念的大小范围之分。而最近本体工程的发展使得很多研究都偏向于将用户兴趣基于本体进行构建。User Profile (UP) 是一种表示用户信息的概念模型，由用户的背景知识生成而得，文献 [37, 38] 中提出 UP 作为描述用户偏好和行为的信息。比如在用户读文章的时候，就可以用这个概念模型来判断该文档是否符合该用户的口味。为了模拟用户的这种概念模型，可以使用本体 (Ontology)，即所谓的 Ontological User Profiles[39, 40]，或者 Personalized Ontology[41]，在文献 [42] 中提出了一种改进后的 Ontological User Profile。UP 可以分为三大类：a) interviewing 模式是最好的 UP，因为它们通过人工的方式来获得的，比如通过问卷调查来分析用户所在的分组，一个典型的例子是 TREC Filtering Track 训练数据集，它就是纯手工采集的数据：受访者在读完某篇调查材料后会给出一个支持或反对的表态，由于只有用户最知道自己的兴趣所在，所以这些答案能十分精确地反映用户背景知识。b) Semi-interviewing 则使用半自动技术来获得用户的信息，该技术往往是提供用户一系列分类列表，并要求用户选择自己喜欢的分类。c) Noninterviewing 则完全不用让用户参与进来，而是观察用户的活动、行为以及背景知识。一个典型的模型是 OBIWAN，其通过用户浏览的历史记录来获得用户偏好。如图??所示，这是一种基于若干种上述方法采集数据后建立的 UP 模型 [43]。

#### 1.3.2.2 用户兴趣挖掘

用户兴趣挖掘技术与文本挖掘类似，但是目的是不一样的。在情感分析 (Sentimental Analysis) 方面，可以使用常见的有监督分类算法对文本进行分类，比如朴素贝叶斯分类器 (Naive Bayesian) 和支持向量机 (SVM)，对用户正负情感进行分类 [44]，当用户对某个文本资源产生负情感时，很有可能说明他对主题的资源没有兴趣，反之亦然。但是，在分类之前的特征选取有所不同，因为文档




图 1.3: 一种基于 Ontological User Profile 的环境模型

中表示情感的词的权重和否定词必须更大，而为了找出那些是具有主观色彩的词汇，又需要借助已经准备好的情感关键词字典等数据集。同理，对于无监督聚类算法也是适用的，并且反而更加接近真实状态 [45, 46]。如果将分析的粒度从文档缩小到句子，也就是主观性分类问题（Subjectivity Classification），一些已有的工作 [47, 48, 49, 50] 在这方面已经表现得十分出色，但是这些工作有一个假设前提，即假每个用户只会对一个句子产生一种情感。另外，单纯地从比较两个情感词不一定能够找出他们之间的关系，这时候依然需要借助于情感字典 [51]，即事先定义好近义词、反义词、上义词和下义词等等，这样就可以匹配两个含义类似但拼写或者写法完全不同的两个词。

### 1.3.2.3 用户兴趣匹配

用户兴趣的匹配主要体现在为兴趣类似的用户推荐资源，在各大电子商务平台中都存在着这样的推荐系统，其背后的原理就是基本的协同过滤算法（Collaborative Filtering）[52, 53]。CF 是在信息过滤和信息系统中正迅速成为一项很受欢迎的技术。与传统的基于内容过滤直接分析内容进行推荐不同，协同过滤分析用户兴趣，在用户群中找到指定用户的相似（兴趣）用户，综合这些相似用户对某一信息的评价，形成系统对该指定用户对此信息的喜好程度预测。典型的协同过滤推荐算法是基于用户的协同过滤推荐算法，其基本原理是利用历史评分数据形成用户邻居，根据评分相似的最近邻居的评分数据向目标用户产生推荐。基于用户的协同过滤推荐是基于这样一个假设：如果用户对一些项目的评分比较相似，则他们对其他项目的评分也比较相似。推荐过程可分为三步：a) 首先获得用户对项目的评分，建立用户一项目评分矩阵；b) 计算目标用户与其他各个用户的相似度，得到目标用户的最近邻居集合；c) 根据其最近邻居对项目的评分信息预测目标用户对未评分项目的评分，取出预测评分最高的前  $n$  项

CF categories	Representative techniques	Main advantages	Main shortcomings
Memory-based CF	* Neighbor-based CF (item-based/user-based CF algorithms with Pearson/vector cosine correlation)	* easy implementation	* are dependent on human ratings
	* Item-based/user-based top-N recommendations	* new data can be added easily and incrementally * need not consider the content of the items being recommended * scale well with co-rated items	* performance decrease when data are sparse * cannot recommend for new users and items * have limited scalability for large datasets
Model-based CF	* Bayesian belief nets CF	* better address the sparsity, scalability and other problems	* expensive model-building
	* clustering CF * MDP-based CF * latent semantic CF * sparse factor analysis * CF using dimensionality reduction techniques, for example, SVD, PCA	* improve prediction performance * give an intuitive rationale for recommendations	* have trade-off between prediction performance and scalability * lose useful information for dimensionality reduction techniques
Hybrid recommenders	* content-based CF recommender, for example, <i>Fab</i>	* overcome limitations of CF and content-based or other recommenders	* have increased complexity and expense for implementation
	* content-boosted CF * hybrid CF combining memory-based and model-based CF algorithms, for example, Personality Diagnosis	* improve prediction performance * overcome CF problems such as sparsity and gray sheep	* need external information that usually not available

图 1.4: 协同过滤推荐算法的综述

推荐给用户，完成推荐。如图 1.4 所示，CF 主要分为三大类，即基于记忆的 CF、基于模型的 CF 和混合 CF。其中，基于记忆的 CF 通常使用用户对资源的评价信息来计算用户之间的兴趣相似度，再根据相似度来给出推荐和预测。该方法的不足之处是由于用户评价过的资源数量相对于资源总数是一个很小的值，导致了数据十分稀疏，从而推荐不准确甚至无法推荐。基于模型的 CF 则直接使用评价的数据来训练模型，并用过模型来做预测，这些模型包括上面提到的主题模型、聚类算法等，但是这些模型本身的缺陷会在 CF 预测的过程中带来潜在影响。混合 Cf 则结合上述两种方法，在一定程度上可以弥补上述方法各自的缺陷。

### 1.3.3 P2P 网络路由搜索相关工作

P2P 网络主要以其非中心化特点为主，因此主要研究问题集中在网络中的搜索技术，但是搜索的方法在很大程度上基于整个网络的拓扑结构，因此下面从拓扑结构和搜索技术两部分来阐述现有工作。

#### 1.3.3.1 P2P 网络的拓扑结构

拓扑结构表示 P2P 网络中各个节点之间在物理或者逻辑上相互连接的关系，主要有四种类型：中心化拓扑、全分布式非结构化拓扑、全分布式结构化拓扑、半分布式拓扑。这四类拓扑结构的优缺点比较如图 1.1 所示。

其中，中心化拓扑结构最为简单，典型的例子是 Napster<sup>3</sup>，该结构与传统的

<sup>3</sup><http://www.napster.com/>

表 1.1: P2P 网络四种拓扑结构的优缺点对比 (A 最好, D 最差)

拓扑	中心化	全分布式非结构化	全分布式结构化	半分布式
可扩展性	D	D	B	C
可靠性	D	B	B	C
可维护性	A	A	B	C
搜索性能	A	C	B	B
复杂查询	支持	支持	不支持	支持

中心化服务器架构类似,普通的节点需要从中央索引服务器中获取其他节点的信息,从而才能进行路由,该结构的好处是十分便于节点搜索复杂的内容,并且速度十分快。但是,该结构的缺陷也十分明显,一旦中央索引服务器宕机时,整个网络就会处于瘫痪状态,因此该拓扑不适用于大型的网络系统。全分布式非结构化拓扑适用于覆盖网络 (Overlay Network),该结构一般基于随机图来构建,节点的度数服从幂定律 (Power-Law) [54],因为节点之间没有严格定义的关系,所以该拓扑具有很好的灵活性,动态变化的结构在容错计算上也有很好表现,经典的案例是 Gnutella[55]。但是,由于该拓扑结构是完全随机的,因此具有一定的不可预见性,在查找和搜索方面也相对复杂很多。全分布式结构化拓扑则是一种综合了上述两种拓扑的特性,使用了分布式散列表 (DHT) 来组织网络中的节点关系,典型的例子包括 Tapestry[56]、Pastry[57] 和 Chord[58] 等等。DHT 的作用是将网络中节点的名字映射到散列表中,这样可以更加快速地进行查找,而且同时也支持动态添加和删除节点。半分布式拓扑 (Hybrid Structure) 则是一种介于中心化结构和完全分布式结构之间的一种拓扑,在网络中存在一些超级节点 (Super Node/Hub),这些节点与中心化拓扑中的中央索引服务器作用类似,提供周围节点的信息。当有源节点提出请求时,这些超级节点会互相通信,找出目标节点的位置等相关信息,并返回给源节点以供其进行连接,一个著名的例子就是 KaZaa[59]。

### 1.3.3.2 P2P 网络的搜索技术

P2P 网络中由于每个节点仅仅存储有限的信息,包括节点本身的网络配置、索引服务器的信息以及周围小部分节点的信息等,因此需要通过搜索算法来找到要与之建立连接的目标节点。在结构化拓扑的 P2P 网络中,搜索算法常常是基于 DHT 查找就能完成。在非结构化拓扑的 P2P 网络中,搜索算法都是基于小世界理论 [60],常见的搜索算法有以下几个 [61]:

- Flood Fill: 这个算法最早用在 Gnutella 协议中,与传统的图算法 BFS 类似,

即先搜索当前节点的所有邻居节点，然后对每个邻居节点执行相同的操作。该方法实现起来十分简单，但是会产生大量的网络流量并造成网络拥堵。

- **Modified-BFS:** 该方法在 Flood Fill 的基础上加上一个概率条件，即以一定的概率选取部分邻居节点，其他不变。
- **Iterative Deepening:** 该方法是在 Flood Fill 的基础上增加了一个阈值 TTL (Time to Live)，从而控制了搜索半径。
- **Random Walk:** 这个算法基于图的 DFS 搜索，首先随机选取源节点的一个邻居节点，并对该邻居节点进行同样操作，直至完成一条完整路径的搜索，然后从源节点开始重新执行这些操作 [62]。
- **Agent-based:** 移动 Agent 是一个在网络中交换和传递资源的程序，也就是所有的搜索的任务都有网络中的 agent 来完成，agent 与 agent 之间也会交换信息，从而实现搜索 [63]。
- **Query Routing:** 这个方法是直接对每个节点的资源建立索引，同时也会记录周围节点的索引信息，所以当查询请求来到时，不用再次转发给其他节点进行搜索，而是直接从索引表中定位到目标资源的位置信息，并直接与目标节点建立连接。

总结来说，这些方法在一定程度上已经十分适应很多分布式的场景，但是随着移动设备的普及，每个移动设备可能也是一个潜在的节点，但是这些设备的加入或退出更大地加剧了网络波动 (Churn)，从而导致整个网络拓扑结构的不稳定，并且如何保证在这种大波动的情况下进行精确的查询和搜索是未来 P2P 网络中搜索技术的一大挑战。

## 1.4 本文内容安排

本文的主要内容安排如下。首先本章对该研究的背景，主要研究内容和研究意义与研究现状进行了一个总体的介绍。第二章将对基于 P2P 网络的信息自主流动机制提出一个完整的技术方案，并且结合研究现状和存在的问题对设计需求和挑战进行详细描述，从而给出关键的技术点。第三章将对解决方案中的第一部分即文本资源的描述与匹配问题进行深入分析，通过结合现有成熟的模型，提出一整套全面的理论模型。第四章将结合第三章的研究基础对用户兴趣进行建模，结合现实中兴趣的动态变化特征给出相应的解决方案。第五章将基于第四章的研究基础提出一种基于 P2P 网络的路由与搜索算法，从而实现动态构建兴趣覆盖网络。第六章将根据第三、四、五章的理论进行模拟实验和真实实验，验证上面提出的新的方法的有效性。第七章则基于前文的研究成果实现了一套简

单的智能系统原型，包括功能设计和系统架构等方面。最后第八章对本研究做了一个总结，并对研究进一步的工作方向进行了讨论。

## 第2章 基于 P2P 网络的信息自主流动机制的方案概述

本章将阐述基于 P2P 网络的信息自主流动机制的基本方案。在整套机制中,需要涉及三大研究模块:在文本信息分析与建模的研究中,主要针对互联网中纯文本的信息的非结构化问题,通过数据挖掘和机器学习等方法从中抽取出一部分能够充分表示原文本的特征,并且提出一套适用于各种类型文本的描述方式;在用户兴趣表示与匹配的研究中,主要结合文本信息与用户反馈提出一种具有代表性的兴趣构建方法,从而可以进行用户与用户、用户与资源之间的兴趣相似度计算。在 P2P 网络路由与发现的研究中,主要利用上述提出的针对资源和用户兴趣的模型,以现在网络为底层架构,构建一层用户兴趣覆盖网络,并提出了网络构建、动态更新与搜索发现等基本方法。最后,基于上述三个模块,本文还设计并实现了一个简易实现的原型系统,主要包括架构设计和功能设计,以此来说明信息自主流动机制的可行性和实际应用价值。

### 2.1 文本信息分析与建模

按照互联网资源的类型可以分为:文本、图片、音乐、视频等。虽然如今涌现了越来越多的诸如音频和视频的流媒体资源,但是互联网上的资源大多任然以文本形式存在,或者可以用文本来代替原有的非文本资源。不仅限于传统的新闻、博客是文本信息,连图片也可以用很成熟的技术来转换成文本,比如百度识图<sup>4</sup>就可以自动识别出图片中的物体,即使是视频资源也可以用元信息、标题、评论和弹幕等文本信息进行概括。因此下文主要针对互联网文本信息进行深入研究,并假设其他类型的资源均可以通过已有成熟的方法转换成文本信息。这一小节将根据互联网上四种不同类型的文本,分别提出文本挖掘与建模的方法。

普通的新闻、博客等文章都归类为长文本信息,这类资源一般都是纯文本数据,因此具有两个明显的特征:稀疏性和高维度。举个例子来说:假设给定一由  $|\mathcal{V}|$  个不同词汇组成的字典  $\mathcal{V}$ , 在由  $M$  篇文章组成的语料库中,每篇文章  $d$  的用词都属于词典  $\mathcal{V}$ , 且每篇文章的单词数量不少于  $n(0 < n \ll W)$ 。如果直接简单地将文档表示成关于词汇的向量,向量中的每个值表示该词汇在文中的词频,如果该词汇没有在文中出现,则向量中对应的值为 0。那么有两点是显而易见的: a) 文档向量的维度为  $|\mathcal{V}|$ , 在正常情况下,  $|\mathcal{V}|$  可以达到百万数量级 ( $10^6$ ); b) 文档向量中最多只有  $n$  个值大于 0, 一般情况下,  $n$  只有几百数量级 ( $10^2$ )。这就是纯文本的高维度和稀疏性带来的问题。为了解决这个问题,本文采用基于概率图的主题模型来进行分析,这里先形式化地定义几个重要的基本概念。

对于包含  $M$  篇文档  $d$  的语料库  $\mathcal{D}$ , 有  $\mathcal{D} = \{d_1, d_2, \dots, d_M\}$ 。词汇表  $\mathcal{V}$  中包含

<sup>4</sup><http://stu.baidu.com/>



了  $W$  个不同的词汇  $v$ 。对于文档  $d_i$ ，其中每个单词  $w$  都取自于  $\mathcal{V}$ ，并且单词可以重复，即  $w_i = w_j = v$  ( $i \neq j, v \in \mathcal{V}$ )。那么，对于长度为  $N$  的文档  $d$  表示为关于单词的向量， $d = \vec{w} = (w_1, w_2, \dots, w_N)$ 。

为了简化模型，一般认为文档单词之间是没有先后关系的，换句话说，每个单词相互独立，一个单词出现的概率不会收到另一个单词的影响。因此可以计算文档  $d$  的生成概率  $p(d)$ ：

$$p(d) = p(\vec{w}) = p(w_1, w_2, \dots, w_N) = p(w_1)p(w_2)\dots p(w_N) \quad (2.1)$$

而对于语料库  $\mathcal{D}$  的生成概率  $p(\mathcal{D})$  为：

$$p(\mathcal{D}) = p(d_1)p(d_2)\dots p(d_M) = p(\vec{w}_1, \vec{w}_2, \dots, \vec{w}_M) \quad (2.2)$$

如果用词频来描述文档的话， $d_m = \vec{n}_m = (n_{m,1}, n_{m,2}, \dots, n_{m,W})$ ，其中  $n_{m,i}$  ( $1 \leq i \leq W$ ) 表示文档  $d_m$  中出现词汇  $v_i$  的频数。于是，整个语料库  $\mathcal{D}$  可以表示为一个  $M * W$  维的矩阵  $X$ ，即：

$$X = \begin{pmatrix} n_{1,1} & n_{1,2} & \cdots & n_{1,W} \\ n_{2,1} & n_{2,2} & \cdots & n_{2,W} \\ \vdots & \vdots & \ddots & \vdots \\ n_{M,1} & n_{M,2} & \cdots & n_{M,W} \end{pmatrix}$$

其中， $n_{m,v}$  ( $1 \leq m \leq M, 1 \leq v \leq W$ ) 表示文档  $d$  中拥有词汇  $v$  的数量。

假设词汇  $v_i$  出现的先验概率为  $p_i$ ，词汇表  $\mathcal{V}$  中所有词汇组成的先验概率为  $\vec{p} = (p_1, p_2, \dots, p_W)$ 。又文档  $d = \vec{n} = (n_1, n_2, \dots, n_W)$ ，那么  $d$  生成的概率为：

$$p(d) = p(v_1)^{n_1} p(v_2)^{n_2} \dots p(v_W)^{n_W} = \prod_{i=1}^W p_i^{n_i} \quad (2.3)$$

从整个语料库来看，假设每个词汇  $v_i$  出现的次数为  $n_i$ ，那么语料库  $\mathcal{D}$  又可以表示为  $\vec{n} = (n_1, n_2, \dots, n_W)$ ，在语料库生成过程中，可以把  $\vec{n}$  看做一个是服从多项分布的随机变量，而  $(n_1, n_2, \dots, n_W)$  是一组具体的观测值，得到如下：

$$p(\vec{n}) = \text{mult}(\vec{n}|\vec{p}, N) = \binom{N}{\vec{n}} \prod_{i=1}^W p_i^{n_i} \quad (2.4)$$

现在的问题是如何利用语料库  $\mathcal{D}$  已知的数据来估计未知的参数  $\vec{p}$ ?  $\vec{p}$  的实际意义是词汇表  $\mathcal{V}$  中每个词汇各自出现的频率。

一种简单的方法是利用最大似然估计 (MLE) 来估计参数  $p_i$  的值得到：

$$\hat{p}_i = \frac{n_i}{N} \quad (2.5)$$

其中  $N$  为语料库的单词总数。这个方法的假设前提是  $\vec{p}$  的值本身是一个实数常量，换句话说，任何其他语料库  $\mathcal{D}'$  的生成过程也是依赖于同一个词汇表来生成的。

但是，这个假设对于互联网上的文本是不正确的，有以下三点主要原因：

- 多类型文档：互联网上的文档类型包括了新闻、技术博客、心情随笔等等，这些文档的用词肯定是很不一样的。比如，对于新闻类型的文档，很少能使用主观色彩的词汇，因此如果将所有新闻文档组成一个词汇表的话，主观性形容词的先验概率是十分低的。但是，这与心情随笔类型的文档恰恰相反，因为此类文档大多是抒发作者内心的心情的，如果将此类型文档组成一个词汇表的话，主观性形容词的先验概率十分高。
- 多元化主题：即使是同一类型的文档也有各种不同主题，比如新闻中就包含体育、娱乐、经济、社会、科技等各种主题。对于不同的主题，生成文档的词汇表应该也是不同的。如果将上述  $\vec{p}$  中的值认为是常数的话，相当于所有文档都是从同一个主题中生成的，这显然违背互联网资源的特征。
- 个性化写作：即使上述两点都保持一致，每个作者写作风格和兴趣爱好同样会影响文档生成的过程。比如说，将每个作者写的所有技术博客各自组成一个词汇表，由于用词习惯等因素，那么这些词汇表中的词汇出现概率肯定也千差万别。

总而言之，一篇文档的生成过程受到包括文档类型的制约、主题风格的用词和用户个性化的定制等几方面的影响。因此，基于这些原因，对互联网文本的表示不能简单地用一个词频向量  $d = \vec{n} = (n_1, n_2, \dots, n_W)$  来表示。

自然而然就考虑到了两个重要的因素。第一，存在不止一个的词汇表，那么  $\vec{p}$  就应该被认为是一个随机变量，所以语料库生成的概率应该是受词汇表影响的一个条件概率  $p(\mathcal{D}|\vec{p})$ 。为了得到随机变量  $\vec{p}$  的分布和参数，可以根据贝叶斯定理得到：

$$p(\vec{p}|\mathcal{D}) = \frac{p(\vec{p})p(\mathcal{D}|\vec{p})}{p(\mathcal{D})} \quad (2.6)$$

其中， $p(\mathcal{D}|\vec{p})$  就是之前的  $\vec{n} = (n_1, n_2, \dots, n_W)$ ，即语料库中每个词汇出现的频数，且和公式 2.4 一样，是一个服从多项分布的随机变量。为了计算方便，这里使得  $p(\vec{p}|\vec{\alpha})$  成为多项分布的共轭先验，也就是 Dirichlet 分布，得到：

$$p(\vec{p}|\vec{\alpha}) = \text{Dir}(\vec{p}|\vec{\alpha}) = \frac{1}{\Delta(\vec{\alpha})} \prod_{i=1}^W p_i^{\alpha_i-1}, \quad \vec{\alpha} = (\alpha_1, \dots, \alpha_W) \quad (2.7)$$

式中的  $\Delta(\vec{\alpha})$  是事先给定的归一化因子：

$$\Delta(\vec{\alpha}) = \int \prod_{i=1}^W p_i^{\alpha_i-1} d\vec{p}$$




图 2.1: LDA 主题模型的概率图表示方式

至此，对于给定  $\vec{\alpha}$ ，语料库  $D$  的生成概率为：

$$p(\mathcal{D}|\vec{\alpha}) = \int p(\mathcal{D}|\vec{p})p(\vec{p}|\vec{\alpha})d\vec{p} \quad (2.8)$$

$$= \int \left( \prod_{i=1}^W p_i^{n_i} \frac{1}{\Delta(\vec{\alpha})} \right) \left( \prod_{i=1}^W p_i^{\alpha_i-1} \right) d\vec{p} \quad (2.9)$$

$$= \frac{\Delta(\vec{n} + \vec{\alpha})}{\Delta(\vec{\alpha})} \quad (2.10)$$

第二，除了词汇表是随机取一个的之外，还可以为每个文档加上主题，这里的主题可以近似看做不同的词汇表，或者更加确切应该是词汇表中词汇的分布。对于互联网文本来说，每篇文档的主题应该不只一个，而且多个主题之间的比重也是不一样的。因此，文档的生成过程应该是先给定一个主题的分布，表示每个主题在文档中占有的比重，然后再根据这个主题的分布随机选取一个主题（也就是词汇表），最后根据这个词汇表生成一个单词。在生成第二个单词的时候，再根据主题分布选择一个主题，并用相应的词汇表生成一个单词。以此类推直至完成一篇文章的生成过程。这个生成过程与 LDA 背后的思想类似，因此就直接引用 LDA 模型的算法进行求解。

如图 2.1 所示，对于  $M$  篇文档、 $K$  个主题的语料库，文档 - 主题的分布为  $\vec{\theta}_m$  ( $1 \leq m \leq M$ )，主题 - 词汇的分布为  $\vec{\phi}_k$  ( $1 \leq k \leq K$ )。这两个随机变量与上文的词汇表类似，且都服从 Dirichlet 分布，即：

$$p(\vec{\theta}|\vec{\alpha}) = \text{Dir}(\vec{\theta}|\vec{\alpha}) = \frac{1}{\Delta(\vec{\alpha})} \prod_{i=1}^K \theta_i^{\alpha_i-1} \quad (2.11)$$

$$p(\vec{\phi}|\vec{\beta}) = \text{Dir}(\vec{\phi}|\vec{\beta}) = \frac{1}{\Delta(\vec{\beta})} \prod_{i=1}^W \phi_i^{\beta_i-1} \quad (2.12)$$

在文档  $d$  中生成第  $n$  个单词的时候，首先要从文档-主题分布  $\vec{\theta}$  中抽样得到的主题编号为  $z_{d,n}$ ，然后选取编号为  $z_{d,n}$  的主题-词汇分布  $\vec{\phi}$ ，并抽样得到的一个单词  $w_{d,n}$ 。由上面的理论可知，从 Dirichlet 分布抽样可以得到的观测值服从多项分布，记  $\vec{x}_d = (x_{d,1}, \dots, x_{d,K})$ ， $x_{d,k}$  ( $1 \leq k \leq K$ ) 表示在文档  $d$  中，抽样得到的编号为  $k$  的主题数量；同理， $\vec{y}_d = (y_{d,1}, \dots, y_{d,W})$ ， $y_{d,v}$  ( $1 \leq v \leq W$ ) 表示在文档  $d$  中，抽样得到的词汇  $v$  的数量。 $\vec{y}_d$  和  $\vec{x}_d$  均为多项分布，即：

$$p(\vec{x}_d | \vec{\theta}_d) = \text{mult}(\vec{x}_d | \vec{\theta}_d) = \binom{N}{\vec{x}_d} \prod_{i=1}^K \theta_i^{x_{d,i}} \quad (2.13)$$

$$p(\vec{y}_d | \vec{x}_d, \vec{\phi}_d) = \text{mult}(\vec{y}_d | \vec{x}_d, \vec{\phi}_d) = \binom{N}{\vec{y}_d} \prod_{i=1}^W \phi_i^{y_{d,i}} \quad (2.14)$$

有了以上基础之后，最终可以得到文档  $d_m = w_m$  的生成概率为 [28]：

$$p(d_m | \vec{\alpha}, \vec{\beta}) = \iint p(\vec{\theta}_m | \vec{\alpha}) p(\Phi | \vec{\beta}) \cdot \prod_{n=1}^{N_m} p(w_{m,n} | \vec{\theta}_m, \Phi) d\Phi d\vec{\theta}_m \quad (2.15)$$

所以整个语料库生成的概率为：

$$p(\mathcal{D} | \vec{\alpha}, \vec{\beta}) = \prod_{m=1}^M p(d_m | \vec{\alpha}, \vec{\beta}) \quad (2.16)$$

现在的问题转换成估计参数  $\Theta = \{\vec{\theta}_1, \dots, \vec{\theta}_M\}$  和  $\Phi = \{\vec{\phi}_1, \dots, \vec{\phi}_K\}$ 。考虑到该问题涉及过多纯统计学知识，下文将直接使用成熟的 collapsed Gibbs Sampling 算法 [64] 进行求解，具体公式将不再列出。

## 2.2 用户兴趣表示与匹配

随着互联网上新型的网站越来越多，用户也会被各种各样的信息资源所吸引，而这些资源的主题可以在一定程度上反映出用户的兴趣所在。因此，将利用之前提出的文本信息分析与匹配方法先挖掘出隐藏在文本背后的主题，然后，通过发现并结合互联网用户兴趣的特点，提出一种可以全面且有效的表示方法和其对应的匹配机制。

首先，目前最常用的表示用户兴趣的方式是 VSM，假设一共存在  $K$  种兴趣，并且兴趣之间没有关联性，而用户的兴趣则表示为一个  $K$  维向量  $\vec{in} = (w_1, w_2, \dots, w_K)$ ， $w_i \in [0, 1]$  ( $1 \leq i \leq K$ )， $w_i$  表示用户对第  $i$  个兴趣的喜好程度。用 VSM 来表示用户兴趣的好处是在计算兴趣相似度的时候速度十分快，一般使用余弦相似度就能计算得出两个向量之间的距离。当余弦值越小就表示用户之间拥有更为相似的兴趣爱好。虽然这个方法在大部分情况下都十分快捷有效，但是，考虑到互联网用户的特点，上述方法存在下面两个问题，因此不能用于完全表示用户兴趣。

- 兴趣关联性：由于用户的兴趣对应于文本资源中的主题，而主题之间是由相关性的，这种相关性体现在两个方面。一是主题之间的同义或反义，比如，CBA 和 NBA 是两个主题，但是它们之间的共同点是都是篮球比赛，区别在于举办地点不同、规则不同等等。二是主题之间有层级关系，比如篮球和 NBA 是两个主题，篮球是一个更加广阔的概念，包括了篮球比赛、篮球运动员、实体篮球等，而 NBA 则是一个相对狭窄的概念，所以 NBA 这个主题是属于篮球的。
- 兴趣动态性：用户的兴趣一般可以分为长期兴趣和短期兴趣。长期兴趣相对稳定，变化较少，构建模型时比较容易。但是短期兴趣是一个难点，因为它会随着时间的变化而变化，而且每次持续的时间也都未知，可以近似把兴趣与时间的关系看成一个随机过程。

为了解决上述两个问题，第三章提出了一套完整的用户兴趣构建方式，包括一种叫做动态兴趣树的兴趣表示方式和一种层级结构的兴趣相似度衡量算法。动态兴趣树的表示方式解决了兴趣随着时间变化的问题，树中的每个节点表示一种兴趣，当用户兴趣发生变化时，这些节点存储的兴趣会通过旋转方式分辨出长期兴趣和短期兴趣。而层级结构的兴趣相似度算法是在主题模型的基础上，增加了层次结构，使得主题之间具有相关性。为了在第四章中更加简单和清晰地阐述这两种方法的构建和维护，这里先对用户兴趣模型的基本概念进行说明。

假设总共有  $K$  种兴趣点构成了兴趣全集  $\mathcal{I}$ ，即  $\mathcal{I} = \{in_1, in_2, \dots, in_K\}$ ，并且事先定义大小为  $|V|$  的词汇表  $V$ 。对于兴趣点  $in_k$  ( $1 \leq k \leq K$ )，是一个关于词汇的向量  $in_k = (w_1, w_2, \dots, w_V)$ ，其中， $w_i$  ( $1 \leq i \leq |V|$ ) 表示词汇  $v_i$  在当前兴趣点  $in_k$  的重要程度。那么，兴趣点之间的相似度计算可以利用余弦相似度来计算两个向量的夹角。

普通的静态兴趣树是一种将兴趣点进行层次分类的表示方式，这种数据结构能够很好地表示出兴趣点之间的关联性。如图??所示，这是一棵四层结构的兴趣树，树上的每个节点表示一种兴趣点，距离根节点越近的节点表示范围越广泛。换句话说，在兴趣树上，父节点表达的兴趣点一般包含了其孩子节点所表达的内容，同时，处于同一层且拥有相同父节点的孩子节点一般具有部分交集的内容。于是，可以对兴趣全集  $\mathcal{I}$  中所有的兴趣点来构建一个完整的兴趣树。具体的构建方法可以分为人工构建法、半自动构件法和自动构建法。人工构建法可以借助词典来进行，因为在词典中定义了部分词汇的上义词、下义词、同义词，如果兴趣点  $in$  的名称正好在这部分词汇内，那么可以直接建立关系，然后再将剩余节点根据人为的经验来判断具体的位置。可以看到这种方法的精确性应该是最高的，因为它十分符合人正常的思维习惯，但是问题也十分明显，即当兴趣全集的数量十分巨大的时候，人工就十分费时费力了。因此，与人工构建法相对的是自

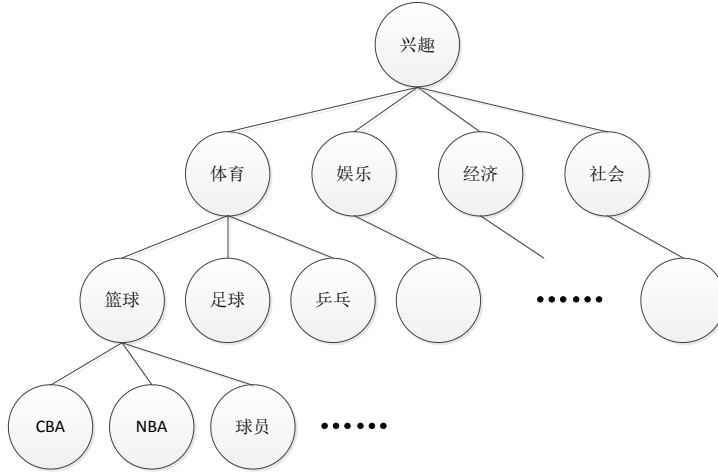


图 2.2: 静态兴趣分类树实例

自动构建法，这种方法基于兴趣点相似度的计算方式，最简单的方法是计算余弦相似度。给定两个兴趣点  $in_i$  和  $in_j$ ，余弦相似度  $sim(in_i, in_j)$  为：

$$sim(in_i, in_j) = cos(in_i, in_j) = \frac{\sum_{k=1}^{|V|} w_{i,k} w_{j,k}}{\sqrt{\sum_{k=1}^{|V|} w_{i,k}^2 \cdot \sum_{k=1}^{|V|} w_{j,k}^2}} \quad (2.17)$$

然后，当构建第二层时（因为第一层的根节点不是兴趣点），对于给定的分类数量  $N$ ，对所有兴趣点进行聚类，可以用常见的 K-means 算法进行计算。对于每一个类中，对每个兴趣点进行两两的相似度计算，从而得到一个兴趣点之间的相关性矩阵  $A$ ：

$$A = \begin{pmatrix} a_{1,1} & \cdots & a_{1,j} & \cdots \\ \vdots & \ddots & \vdots & \\ a_{i,1} & \cdots & a_{i,j} & \cdots \\ \vdots & & \vdots & \ddots \end{pmatrix}$$

其中， $a_{i,j} = sim(in_i, in_j)$ 。接着，对矩阵  $A$  中的每个行向量计算均值  $mean(\vec{a}_i)$  和方差  $var(\vec{a}_i)$ ，选择均值较大方差较小的行向量，其对应的兴趣点作为第二层的一个节点。依次类推完成其他节点的构建。可以发现，自动构建法适用于大规模兴趣点的场景，但是精确度比人工构建法会差一点，因此，一般使用半自动构建法，即结合人工反馈的方式和自动分类的方式进行构建，具体方法将在第四章中详细说明。同时，对于每个用户  $u$  来说，其各自还需要维护一棵兴趣子树，从而可以进行用户之间两两的兴趣匹配。

此外，这种静态的分类兴趣树仅仅描述了兴趣点之间的关联性，但是用户的兴趣还分为长期兴趣和短期兴趣，对于动态变化的短期兴趣来说，这种静态的结构不太适合，因此提出了一种基于二叉伸展树结构的动态兴趣树，其基本原




图 2.3: 动态兴趣伸展树实例

理是每当用户有新的兴趣加入时，将交换已有树中的节点位置，离根节点越近的节点说明是用户最新的兴趣，相反离得越远的节点说明用户只是在很久以前曾经有过的兴趣。如图 2.3 所示，当系统发现最近用户对季后赛有了浓厚的兴趣时，伸展树的结构就会发生变化，季后赛节点从左边旋转到根节点，表示用户当前最感兴趣的一项。

二叉伸展树是一种自适应的二叉搜索树，其遵循的特点是近期访问过的节点将会在不久之后又被访问到。对于诸如插入节点、查找节点、和删除节点等基本操作都在  $O(\log n)$  的时间内。对于一系列非随机的操作，伸展树的性能比其他搜索树表现得更好。这一点尤为重要，因为在互联网中，用户的兴趣变更十分频繁，这些变更的操作包括了加入新的兴趣、重新对已有兴趣有了热情等等，之所以选择二叉伸展树就是因为其可以表现出这个特征。另外，伸展树的性能在一定程度上取决于它的自优化过程，频繁操作的节点比不操作的节点更容易接近根节点。伸展树的高度在最坏情况达到了  $O(n)$ ，但平均情况稳定在  $O(\log n)$ ，最坏情况下伸展树的高度成为了最主要的弊端。

但是，在兴趣伸展树中不能体现出兴趣点之间的联系，因此需要将静态和动态的兴趣树结合起来判断用户的完整兴趣，具体方法将在第四章中详细说明。

### 2.3 P2P 网络构建与发现

基于上述两部分的工作，接下来要在已有的网络架构上建立一层 P2P 网络来实现信息自主流动的机制。在构建网络之前，必须确保理解以下几个关于信息流动的问题。

- 信息流动的目的：互联网上的信息内容众多，但是用户真正需要的信息不

多，因此信息流动的本质是为了让用户获得更多有用的信息，过滤掉相对没用的信息。这个过程与信息推荐有所类似，但是也有所不同，相同点是用户都是被动地接受处理过后的信息，但不同点是，现在推荐系统都是基于集中式的架构，而此处信息流动是一个更加广域的概念，其基础是建立在 P2P 的网络中。

- 信息流动的依据：在文本中，用户有用的信息是指用户真正感兴趣的内容，用户兴趣模型的作用就是先挖掘出用户的潜在兴趣，然后匹配信息的主题与用户兴趣之间的关联度，并进行推荐。换句话说，信息流动是由用户兴趣所驱动的，因此只要衡量目标用户的兴趣与信息发布者的资源是否相似即可。

因此，要建立的 P2P 网络是建立在用户兴趣的基础之上的，或者更确切的说法是，将在已有的网络架构上添加一层基于 P2P 架构的用户兴趣覆盖网络，从而使得信息能够在这一层网络中进行自动传播。为了说明兴趣覆盖网络的基本概念，本节用暂时使用 VSM 模型来表示用户兴趣。

首先，在基于 P2P 架构的兴趣覆盖网络上，先有一层用户好友关系层。其中，每个用户表示一个节点，用户集合  $U$  可以表示为：

$$U = \{u_1, u_2, \dots, u_{|U|}\}$$

$|U|$  表示用户集合的大小。

在目前传统的网络中，用户之间可以相互加为好友，把这种好友的关系定义为 follower 和 followee 的单向关注的关系：

$$\forall u_i, u_j \in U, \exists e_{i,j} : u_i \rightarrow u_j$$

如果用户  $u_i$  关注了用户  $u_j$ ， $u_i$  和  $u_j$  之间则存在一条边  $e_{i,j}$ 。那么所有的关注关系集合  $E_f$  可以表示为：

$$E_f = \{e_{i,j} | u_i \rightarrow u_j, 1 \leq i, j \leq n\}$$

于是用户集合和关系集合构成一张有向图  $G_f = \{U, E_f\}$ 。

接下来，要在用户好友关系层上加上兴趣覆盖网络。假设兴趣全集定义与上面相同，即表示为：

$$\mathcal{I} = \{in_1, in_2, \dots, in_{|\mathcal{I}|}\}$$

用户  $u$  的兴趣可以用向量简单地表示为：

$$d_u = (w_{u,1}, w_{u,2}, \dots, w_{u,|\mathcal{I}|})$$






图 2.4: 基于向量表示的兴趣覆盖网络实例

其中  $w_{u,i} \in [0, 1]$  ( $1 \leq i \leq |I|$ ) 表示用户  $u$  对兴趣点  $in_i$  实际感兴趣的程度。对于给定的阈值  $\epsilon$ ，当且仅当  $w_i > \epsilon$  时，称用户  $u$  拥有兴趣点  $in_i$ ，否则用户  $u$  不拥有兴趣点  $in_i$ 。

对于两个用户  $u_i$  和  $u_j$ ，他们的兴趣向量分别是  $d_{u_i}$  和  $d_{u_j}$ ，如果存在  $k$  ( $1 \leq k \leq |I|$ )，满足条件：

$$w_{u_i,k} > \epsilon \text{ 并且 } w_{u_j,k} > \epsilon$$

那么称用户  $u_i$  和用户  $u_j$  分享共同的兴趣点  $in_k$ 。于是在兴趣覆盖网络中，这两个节点之间存在一条边  $v_{i,j}^k : u_i \xleftrightarrow{k} u_j$ 。兴趣关系集  $V_i$  则表示为：

$$V_i = \{v_{i,j}^k | u_i \xleftrightarrow{k} u_j, 1 \leq i, j \leq n\}$$

用户集合与兴趣关系集合组成了兴趣覆盖网络  $G_i = \{U, V_i\}$ 。

如图 2.4 所示，在一个简化的四节点的网络结构中，可以看到在用户关注关系层上， $u_1, u_2, u_3, u_4$  四个用户之间存在着单向的关注关系，但是在这一层上不能直观地看到用户之间存在哪种相关性，这导致了在路由搜索的时候性能下降（在搜索过程中再进行匹配会很慢）。所以，在用户关注关系层上添加了一层用户兴趣关系层，在这一层中，四个用户相对位置并没变化，但是他们之间多出了几条彩色的边，即共同兴趣关系边，这里不同的颜色表示不同的兴趣点。两个用户

之间可以存在一条或多条兴趣边，因为他们之间可能存在的共同兴趣不止一个。当然，在这一层中，节点之间存在多条边的关系不能在后续搜索过程中进行路由，甚至会造成多重环的问题。所以，在计算过程中，可以将两节点间多条边转换成一条权重为向量的边，具体计算方式会在第五章中详细阐述。

## 2.4 小结

在这一章中，简单阐述了基于 P2P 网络的信息自主流动机制的方案，在这一机制中主要涉及三大模块：文本信息的分析与建模、用户兴趣的表示与匹配和 P2P 网络的构建与发现。其中，在文本信息分析与建模的问题中，分析了直接用 VSM 模型来描述互联网资源的弊端，并且根据问题的根结所在，提出了用主题来表示资源是一个更好的方法。一方面对文本的高维度进行了降维，另一方面也表达出了文本隐藏在背后的含义。然后，通过模拟文本的生成过程，从而解释了对文本主题求解的基本方案。在用户兴趣表示与匹配的问题中，首先基于兴趣之间的相关性和兴趣动态变化两大特点，分别提出了两种解决方案：静态兴趣分类树和动态兴趣伸展树。在 P2P 网络的构建与发现问题中，引入了兴趣覆盖网络这一概念，并且用简单的基于 VSM 的兴趣模型来说明兴趣覆盖网络的直观意义和表示方法。

## 第 3 章 互联网文本信息分析与建模的研究

本章将从互联网文本信息的特征入手，详细分析与研究各种特征下的文本建模方法。根据第二章的分析，工作主要集中在对文本的主题进行建模与分析，根据不同文本的特征，包括长文本、短文本、文本间相关性以及动态文本等方面，提出有针对性的主题分析方法。利用主题模型对文本进行建模的好处有两个，一是可以对高维度的词汇向量进行降维，也就是用低维度的主题向量来表示文档；二是完全遵循用户生成文档的习惯，一般会先选取几个文档的主题，然后根据主题来生成单词，而主题模型则是很好地模拟了这一过程。

### 3.1 长文本信息的分析与建模方法

所谓的长文本信息一般是指新闻、博客等篇幅相对较长的文本，而评论、微博、弹幕等文本则属于短文本，关于短文本的分析将在下一节进行讨论。在分析之前，首先给出长文本分析问题的形式化描述：

**定义 3.1 (长文本主题识别问题)** 给定大小为  $K$  的主题集合  $\Phi = \{\vec{\varphi}_1, \vec{\varphi}_2, \dots, \vec{\varphi}_K\}$ ，以及文档  $d = \vec{w} = (w_1, w_2, \dots, w_{|d|})$ ，求出文档  $d$  的主题向量  $\vec{\tau} = (\tau_{k_1}, \tau_{k_2}, \dots, \tau_{k_l})$ ，使得在  $l$  最小的情况下满足  $\epsilon < (\sum_{i=1}^l \tau_{k_i}) \leq 1$  ( $\tau_{k_i} \in [0, 1], k_i \in [1, K]$ )。

在长文本分析中，需要解决的问题是如何识别出给定的文档主题，而主题集合可以通过已有的主题模型对语料库进行训练来得到，因此在问题定义中，主题向量  $\vec{\varphi}$  被认为是已知条件。这里问题的难点在于如何将已知的主题赋给新来的文档，找出文档中权重排名前  $l$  的主题，并且使权重之和大于一个给定的阈值  $\epsilon$ ， $\epsilon$  的含义是选出的文档能在多大的程度上表示原文。其中  $\tau_{k_i}$  表示主题编号为  $k_i$  在这篇文档中的权重值， $i$  表示这个权重值从高到低排在第  $i$  位。

#### 3.1.1 基于相似度的长文本主题识别算法

这个算法的思路是将主题集合中的所有主题分布与输入文档计算余弦相似度，从而得到一个相似度向量，然后对这个向量进行归一化处理，然后从大到小对向量中的每个值进行排序，取出前  $l$  个总和达到  $\epsilon$  的主题，从而得到主题向量。

从图 3.1 中可以发现，主题集合中的  $K$  个主题分布  $\vec{\phi}_1, \vec{\phi}_2, \dots, \vec{\phi}_K$  在经过 LDA 推理后，其每个值得到的都是关于词汇表  $V$  中词汇的权重，从而组成一个  $|V|$  维的向量，这与文档向量  $\vec{w}$  的维数是一样的，当然这里的  $\vec{w} = (n_1, n_2, \dots, n_{|V|})$ ，即对词汇表中每个词汇的频数（因为这里只有一篇文档，没有办法将文档向量表示成 TF-IDF 值）。然后通过计算主题分布于文档向量间的相似度  $d_k = \text{sim}(\vec{\phi}_k, \vec{w})$ ，得到一个新的  $K$  维向量，记为  $\vec{s} = (d_1, d_2, \dots, d_K)$ ，但是这个向量中每个值之和




图 3.1: 基于相似度的长文本主题识别算法过程示例

并不为 1，因此要进行一次归一化操作从而得到一个修正后的向量  $\vec{s}'$ ：

$$\vec{s}' = (d'_1, d'_2, \dots, d'_K), \quad (d'_k = \frac{d_k}{\sum_{i=1}^K d_i}, k \in [1, K]) \quad (3.1)$$

其中  $d'_k$  表示文档  $d$  拥有第  $k$  个主题的权重。然后，对  $\vec{s}'$  中的每个值进行从大到小的排序，排序后得到向量  $\vec{s}'' = (d_{k_1}, d_{k_2}, \dots, d_{k_K})$ ，其中  $d_{k_i}$  表示文档中编号为  $k_i$  的主题占有的权重， $i$  表示该主题所占的权重在文档  $d$  中的重要性排在第  $i$  位。最后，对于给定的  $\epsilon$ ，在  $\vec{s}''$  中选择前  $l$  个主题且满足  $\sum_{i=1}^l d_{k_i} > \epsilon$ 。这时文档  $d$  的主题向量  $\vec{\tau}$  为：

$$\vec{\tau} = (d_{k_1}, d_{k_2}, \dots, d_{k_l}) \quad (l \in [1, K]) \quad (3.2)$$

这个算法的时间复杂度是  $O(K \cdot |V|)$ ，因为在计算主题分布和文档的相似度时，消耗的时间是  $O(K \cdot |V|)$ ，在之后对向量权重进行排序的时候，平均时间复杂度达到  $O(K \cdot \log K)$ ，很显然  $\log K \ll |V|$ ，所以总共的时间复杂度是  $O(K \cdot |V|)$ 。

### 3.1.2 基于标签的主题分析技术

对于上述提出的算法，可以基本实现对新文本进行主题标注的功能，但是上述算法存在一个很重要的问题，准确地说应该是主体模型 LDA 导致的一个问题。因为 LDA 是无监督学习，与 K-mean 等聚类算法相似，虽然它们可以计算出最后  $K$  个主题分布，但是对于每个主题分布的实际含义还需要人工标注，通过观察主题分布中的主题词来判断用什么词可以概括相应的主题。如表格 3.1 所示，第一行中的主题名称都是有人工标注的，这无疑造成了很大的麻烦，原因如下。

- 自动化：在信息自主流动的机制中，由于主题数量巨大，主题也会不断地更

表 3.1: 主题模型训练后的主题示例  
“艺术” “财务” “孩子” “教育”

新的	百万	小伙伴	学校
电影	税收	女性	学生
展览	项目	人们	大学
音乐	上亿	多年	教育
影片	政府	家庭	教师
播放	每年	工作	高等
乐器	开销	家长	公开的
最好的	全新的	说	多媒体
演员	省市	回家	基础的
首次	计划	福利	试卷
戛纳	资金	爸爸	丰富的
剧院	扶植	比例	电子化
电影院	企业	关心	准时
爱	繁荣	生活	兴趣
票房	单位	愉快的	山区

新，因此用户不适合每次都使用手动标注，更好的办法是将更多的任务交给每个节点的智能系统进行处理。

- 歧义性：在表格中可以看到，虽然第一列标注为艺术，但是这一列的主题词也可以换成一个更加小的概念，比如电影艺术等等。同样第二列主题标注为财务，但是同样也可以认为是预算、经济等相同意义的词。

对于如今的互联网文本来说，文本资源其实不仅仅包含纯文本，而且还有一些元数据，其中最常见的新闻和博客资源中还包含了标签信息。因此，现在的问题是如何利用这些文本的标签的信息来重新训练主题，使得训练出来的主题都自动分配到一些标签。这里有两个问题，一个是如何通过语料库训练出带有标签的主题，另一个是如何给文档赋上多个带有标签的主题。对于第一个问题，一个比较成熟的方法是利用 Labeled-LDA 模型，或者 L-LDA[65] 重新训练这些主题。这里先对 L-LDA 模型进行简单的说明，进而对比该模型生成的主题与传统 LDA 生成的主题的不同之处，以及如何在下文中的进行修改使用。

L-LDA 同样是一个概率图模型，其模拟了一个带有标签的文档集合的生成过程，换句话说，其充分利用了互联网上文档自带的标签数据。与 LDA 相同的地方是在生成过程中，每个单词依然是从一个选定的主题中生成的，但不同的是，

该模型是一种有监督学习算法，通过分析标签与主题之间的对应关系来判断文档对应的标签是什么。接着前文对 LDA 的形式化定义，现在假设共有  $K$  个不同的标签对应  $K$  个不同的主题，完整的生成过程如下：首先从给定的参数  $\vec{\beta}$  的 Dirichlet 分布中抽样得到  $K$  个主题分布  $\Phi = \{\vec{\phi}_1, \vec{\phi}_2, \dots, \vec{\phi}_K\}$ ，这一步与 LDA 中一样。与 LDA 直接从给定参数  $\vec{\alpha}$  的 Dirichlet 分布中取样得到的文档-主题分布  $\Theta = \{\vec{\theta}_1, \vec{\theta}_2, \dots, \vec{\theta}_W\}$  不同的是，在 L-LDA 中先要限制  $\Theta$  使其能与标签一一对应。于是，在这个过程中先生成文档  $d$  的标签  $\vec{\Lambda}_d$ ，使其从伯努利分布中进行抽样，即

$$\Lambda_{d,k} \in \{0, 1\} \sim \text{Bernoulli}(\cdot | \Gamma_k)$$

其中， $\Gamma_k$  是标签的先验概率。接着，定义文档的标签向量为  $\vec{\lambda}_d = \{k | \Lambda_{d,k} = 1\}$ ，从而可以为每个文档  $d$  定义一个  $M_d \times K$  维的标签映射矩阵  $L_d$ ，其中  $M_d = |\vec{\lambda}_d|$  对于矩阵中的每一行  $i \in \{1, \dots, M_d\}$  和每一列  $j \in \{1, \dots, K\}$  有：

$$L_{d,i,j} = \begin{cases} 1 & \text{if } \lambda_{d,i} = j \\ 0 & \text{otherwise} \end{cases} \quad (3.3)$$

换句话说，如果矩阵中的第  $i$  行在第  $j$  列的值是 1 的话只有当第  $i$  个文档标签  $\lambda_{d,i}$  等于编号为  $j$  的主题，否则就是 0，这样就限制了主题和标签一一对应的关系。同时，这个矩阵  $L_d$  可以用来对 Dirichlet 分布中的超参数  $\vec{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_K)^T$  进行降维，得到文档  $d$  自己的超参数  $\vec{\alpha}_d$ ：

$$\vec{\alpha}_d = L_d \times \vec{\alpha} = (\alpha_{\lambda_{d,1}}, \dots, \alpha_{\lambda_{d,M_d}})^T \quad (3.4)$$

很明显可以看到，这个向量的维度原本是受主题数量决定的，现在转而由标签数量决定。在完成上面这个额外的过程后，原本的文档-主题分布  $\vec{\theta}_d$  可以从改进后的超参数  $\vec{\alpha}_d$  来取样。最后根据 LDA 中的生成单词方法继续执行。关于这个模型参数训练方法不再详细赘述，推理过程将直接参照文献 [65] 中的方法。

如图 3.2 所示，左半部分为 LDA 模型的层次结构，右半部分为 L-LDA 模型的层次结构。通过对比可以发现，两种模型的目标都是为了推理计算出主题的隐藏层，但是 L-LDA 比 LDA 多出了一层标签（中间三角形）。而这一层的目的也十分地明确，一方面是为了找到与主题一一对应的关系，弥补原本 LDA 无监督学习导致的主题名称不明确的问题；另一方面是在训练过程中减少了工作量，如上述公式中  $\vec{\alpha}$  由原本的  $K$  维降到了向量  $\vec{\alpha}_d$  的  $M_d$  维，因此添加标签这层导致了一个一举两得的结果。

### 3.1.3 基于标签的长文本主题识别算法

现在利用 L-LDA 训练出的带有标签的主题对长文本主题识别问题的算法进行修正：首先保持估计出来的主题-单词分布  $\Phi$  保持不变，对新文档的每个单词




图 3.2: LDA 模型与 L-LDA 模型之间的区别

随机一个主题编号，然后通过 Gibbs Sampling 采样出每个单词新的主题编号，反复迭代直至 Gibbs Sampling 收敛，最后统计该文档中主题分布  $\vec{\theta}_d$ ，选取前  $l$  个主题使得它们的权重达到  $\epsilon$ ，这样就初步推理出了文档的主题集合的一个解。随后，再按照之前基于相似度的主题识别算法中同样的步骤计算出该文档的主题集合的第二个解。通过选取两个解集合中的交集主题，并找到这些主题对应的标签，从而得到文档的标签集合。之所以计算两次主题向量并再取交集的原因是：

- 文档标签数量很少：因为 L-LDA 模型适用于互联网上带有标签的文档，而通过统计和观察，这些文档的平均标签数相对于主题的数量是十分少的，只有 2-3 个。但是，在第一个主题识别算法中，主题选取的数量依赖于给定的阈值  $\epsilon$ ，当  $\epsilon$  达到 95% 的时候，根据普通 LDA 对文本数据集的实验结果来看，每个文档会 7-8 个主题，因此是不符合实际情况的。通过去交集的办法可以过滤掉一些可能是噪声的主题。
- 主题数量的不确定性：因为在两个模型中，主题数量  $K$  都是人工确定给定，因此  $K$  的大小会间接决定了文档最后的标签数量。而 L-LDA 是根据已有文档的标签集合进行有监督的学习，因此在控制每个文档的标签数量上更加出色。

## 3.2 短文本信息的分析与建模方法

互联网中的短文本一般包括各种资源的评论、微博的内容，甚至是资源的元数据，针对这些数据的分析目前已经有比较的研究，在此就不再罗列。本节要研究的短文本信息是一种新型出现的视频弹幕，考虑到这种弹幕数据独有的特性，因此可以用来对视频精彩片段进行提取和索引。相比于利用图像技术进行视频精彩镜头提取的工作，利用弹幕短文本来做优势是：

1. 图像本身很难被计算机充分理解，因为视频中讲述的故事很难用像素点来表示，计算机不像人类一样可以通过图像描述的方式来理解这些隐藏的主题。
2. 当用户对视频进行查询时，一般是通过输入文本信息的，因为这是一种简单而有效的交互方式，所以这不可避免需要进行文本和图像之间的转换。虽然现在已经有技术来实现这一功能，但是相比文本的匹配过程，这种技术显然是更加耗时耗资源的。

基于上述理由，一种更好的方式是利用弹幕这种带有时间戳的短文本对视频的精彩镜头进行描述。这节的研究成果所发表的论文已经被 ACM MobiHoc 2015 - HotPOST '15 录用，其中 MobiHoc 是 CCF 推荐的 B 类会议，HotPOST 是其下的一个 workshop。在这一节中，将简单说明该论文的内容。

### 3.2.1 视频精彩镜头的抽取问题

为了简化问题，假设弹幕的文本内容可以充分用一个关键词来表示，关键词来自一个充满情感词的词典，这样做的理由是：

- 直观上来看，每个用户在看完一个精彩镜头之后都会触发最多一种情感，所以弹幕的内容应该是单一的。比如看完一个恐怖镜头之后，人可能会感到恐惧。
- 统计上来说，弹幕是典型的短文本，在本文的数据集中平均只有 6.28 个中文字符。

首先来形式化定义一下待解决的问题。一个时间长度为  $T_v$  秒的视频  $v$  可以被分割成一个连续小段的序列， $v = f_{v,1}, f_{v,2}, \dots, f_{v,N_v}$ ，其中小段  $f_{v,i}$  ( $1 \leq i \leq N_v$ ) 的时间长度是固定的  $T_f$ ，比如是 256 毫秒。显然，视频  $v$  中小段的数量  $N_v = T_v/T_f$ ，其中最后一个小段可能比  $T_f$  短。类似的，精彩镜头  $s_v$  也是视频  $v$  中的一个连续子序列，记作  $s_v = \{f_{v,i}, f_{v,i+1}, \dots, f_{v,j}\}$  ( $1 \leq i \leq j \leq N_v$ )。基于之前的假设，本文的弹幕表示成三元组  $c_{v,i} = (w, t_0, T_c)$ ，其中  $w_k$  是来自词典  $\mathcal{W}$  的情感词， $t_0$



表 3.2: 本模型中用到的符号

SYMBOL	DESCRIPTION
$v$	time-sync commented video
$T_v$	video length (time duration)
$N_v$	total number of frames in video $v$
$f_{v,i}$	$i$ -th frame in video $v$
$T_f$	frame length (time span)
$s_v$	highlight shot in video $v$
$c_{v,i}$	$i$ -th TSC in video $v$
$w$	sentimental keyword of TSC
$t_0$	start time stamp of TSC
$T_c$	TSC length (time span)
$M_v$	total number of TSCs in video $v$
$e_v$	global emotional feature of video $v$
$\mathcal{V}$	video corpora of size $ \mathcal{V} $
$\mathcal{C}$	TSC corpora of size $ \mathcal{V} $
$\mathcal{W}$	sentimental keywords dictionary of size $ \mathcal{W} $

是弹幕在视频  $v$  中的开始时间戳,  $T_c$  是弹幕出现在屏幕上的持续时间, 每个视频的弹幕集合通常包括了很多不同的关键词和开始时间戳。对于视频  $v$  中的弹幕集合记为  $\vec{c}_v = \{c_{v,1}, c_{v,2}, \dots, c_{v,M_v}\}$ 。所有符号见表 3.2 所示, 精彩镜头、视频小段和弹幕的关系如图 3.3 所示。

下文将主要关注视频的精彩镜头抽取和查询的过程, 问题定义如下:

**定义 3.2 (视频精彩镜头的抽取问题)** 给定视频  $v$  和其弹幕集合  $\vec{c}_v$ , 求出可能的精彩镜头集合  $\vec{s}_v = \{s_{v,1}, s_{v,2}, \dots\}$ , 且任何两个  $s_{v,i}$  和  $s_{v,j}$  是不相交的。

**定义 3.3 (视频精彩镜头的查询问题)** 给定查询的精彩镜头  $s_q$ 、视频  $v$  和对应的弹幕  $\vec{c}_v$ , 求出视频  $v$  中的具有相似情感的精彩镜头。

为了解决上述两个问题, 我们需要做的是:

1. 如何利用弹幕来描述小段、镜头和视频;
2. 如何计算小段与小段、镜头与镜头之间的相似度;
3. 如何自动发现精彩镜头的边界;




图 3.3: 视频、小段、镜头和弹幕之间的关系

### 3.2.2 弹幕短文本的特征

对弹幕这种短文本的特征进行研究有助于计算视频小段间的相似度。因为弹幕之前被定义成一个三元组  $c = (w, t_0, T_c)$ ，假设关键词  $w$  已经从现有技术从原始评论文本转换来的。经验上，用户只有当他被当前或者临近的前几个镜头所感染，这说明了弹幕只是在时间段  $[t_0, t_0 + T_c]$  的开头更加有效。所以，这里提出了一种弹幕强度在时间段  $[t_0, t_0 + T_c]$  上的衰退函数  $g_c$ ：

$$g_c(t) = \begin{cases} T_c^{t_0-t}, & \text{if } t_0 \leq t \leq t_0 + T_c \\ 0, & \text{otherwise} \end{cases} \quad (3.5)$$

可以看到，弹幕在  $t_0$  的时候强度最大，在之后的  $T_c$  秒内，强度逐渐趋向于 0，这解释了弹幕在不同时间戳的时候是如何反应用户情感的。

### 3.2.3 视频小段的表示和相似度

如图 3.3 表示，每个小段都或多或少包含了一些弹幕，所以最简单的方式来描述小段是用一个关于关键词词频的向量  $f = (n_1, n_2, \dots, n_{|\mathcal{W}|})$ ，其中  $n_i (1 \leq i \leq |\mathcal{W}|)$  是词典中第  $i$  个关键词在小段中出现的数量。举例来说，在小段  $f_1$  的区间上，有三个关键词  $w_1$ 、 $w_2$  和  $w_3$ ，因此  $f_1 = (1, 1, 1, 0, 0, \dots)$ 。Jaccard 相似度可以用于计算小段之间的相似程度，但是当两个小段中的关键词都是同义词时，就不适用了。根据弹幕强度衰退函数来看，关键词的强度是一个更好的选择，另一方面，弹幕在每个视频小段内的数量都远小于  $M_v$ ，因此会导致小段的歧义性。

所以，在时刻  $t$ ，小段  $f_v = (g_1, g_2, \dots, g_{|\mathcal{W}|})$  中的关键词强度向量可以计算为：

$$g_i = \sum_{c \in \vec{c}_f} g_c(t) \quad (3.6)$$




图 3.4: 对于关键词强度向量的每一维度, 找出所有的弹幕使得其时间区间与小段的时间区间相交

其中  $\vec{c}_f$  是视频  $v$  的弹幕的集合:

$$\vec{c}_f = \{c | w = w_i, t - T_c < t_0 < t + T_f\}$$

图 3.4 解释了弹幕关键词关于小段的表示方式。

但是, 利用视频小段的关键词强度向量来计算 Jaccard 相似度仍然有不足, 因为每个小段的弹幕数量是十分有限的。为了解决这个问题, 引入一个新的变量  $e_v$ , 称为视频  $v$  的全局情感特征。在实际的例子中, 全局情感特征与用户在看完一个精彩镜头之后抒发的情感是一致的。同时, 精彩镜头中的局部情感特征在一定程度上组成了全局情感特征, 而且精彩镜头和视频都是由小段组成的。鉴于此原因, 特征相似度的计算在小段和全局情感特征间进行, 而不是小段间的相似度。

为了获得视频  $v$  的全局情感特征, 这里使用了传统的 LDA 主题模型。原本文本中的文档-主题-词汇三层关系转换成了视频-特征-弹幕的关系, 其中弹幕中的关键词与单词是类似的。另一方面, 这里的视频仅仅考虑文本信息, 而排出了图像信息, 所以它可以表示为一个带有权重的全局情感向量。类似于文档的主题, 全局情感特征是一个隐藏变量, 并定义为关于关键词的分布,  $e_v = (n_1, n_2, \dots, n_{|V|})$ , 为了简化问题, 假设总共只有  $K$  个不同的特征。

在应用 LDA 之前, 弹幕生成的过程与文档的生成过程有两个小区别:

- **精彩镜头的影响:** 精彩镜头是视频中额外的特殊元素, 而在文件中没有完全相同的概念。正如前文所说, 弹幕的主要是受精彩镜头影响, 更具体地说, 是局部情感特征。为了简化问题, 这里特意把弹幕的生成, 通过大体上, 由视频, 即全局情感特征的影响。在实验中, 我们表明, 这种近似计算还执行比其他传统的方法要好得多。
- **弹幕密度影响:** 弹幕的密度反映了弹幕视频的特征, 因为一些现有的工作使用频率提取镜头。不同于文档, 其中的每一个单词是依次产生并均匀地

分布的，而弹幕生成的不确定性取决于用户的感觉是否将被某个镜头所触发。例如，弹幕更可能在精彩镜头的区间内生成。

### 3.3 文本网的分析与建模方法

### 3.4 文本流的分析与建模方法

### 3.5 小结

## **第 4 章 用户兴趣表示与匹配的研究**

- 4.1 分类兴趣树的构建与更新方法
- 4.2 动态兴趣树的构建与更新方法
- 4.3 用户兴趣的自适应学习方法
- 4.4 小结

## **第 5 章 基于 P2P 网络的信息自主流动机制的研究**

- 5.1 用户兴趣覆盖网络的构建
- 5.2 兴趣覆盖网络的资源传播
- 5.3 兴趣覆盖网络拓扑结构的更新
- 5.4 小结

## 第 6 章 实验分析与结果分析

### 6.1 小结

## 第 7 章 原型系统设计与实现

### 7.1 小结



## 第 8 章 结论与展望

## 致谢

逾尺的札记和研究纪录凝聚成这么薄薄的一本,高兴和欣慰之余,不禁感慨系之。记得鲁迅在一篇文章里写道:“人类的奋战前行的历史,正如煤的形成,当时用大量的木材,结果却只是一小块”。倘若这一小块有点意义的话,则是我读书生活的最好纪念,也令我对于即将迈入的新生活更加充满信心。回想读书生活,已经整整二十个年头,到同济求学将近五年,攻读博士学位也已三年了。进入同济大学以来,深深醉心于一流学府的大家风范。名师巨擘,各具特点;中西融合,文质相顾。处如此佳境以陶铸自我,实乃人生幸事。

2015 年 3 月

## 参考文献

- [1] 罗杰文, ``Peer to peer (p2p) 综述," 2005.
- [2] J. Han, M. Kamber, and J. Pei, *Data mining, southeast asia edition: Concepts and techniques*. Morgan kaufmann, 2006.
- [3] W. B. Croft, D. Metzler, and T. Strohman, *Search engines: Information retrieval in practice*. Addison-Wesley Reading, 2010.
- [4] D. A. Grossman, *Information retrieval: Algorithms and heuristics*, vol. 15. Springer Science & Business Media, 2004.
- [5] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to information retrieval*, vol. 1. Cambridge university press Cambridge, 2008.
- [6] G. Salton and M. J. McGill, ``Introduction to modern information retrieval," 1983.
- [7] D. E. Appelt, J. R. Hobbs, J. Bear, D. Israel, and M. Tyson, ``Fastus: A finite-state processor for information extraction from real-world text," in *IJCAI*, vol. 93, pp. 1172--1178, 1993.
- [8] R. Mooney, ``Relational learning of pattern-match rules for information extraction," in *Proceedings of the Sixteenth National Conference on Artificial Intelligence*, pp. 328--334, 1999.
- [9] R. Dugad and U. B. Desai, ``A tutorial on hidden markov models," *Signal Processing and Artificial Neural Networks Laboratory Department of Electrical Engineering Indian Institute of Technology*, 1996.
- [10] A. L. Berger, V. J. D. Pietra, and S. A. D. Pietra, ``A maximum entropy approach to natural language processing," *Computational linguistics*, vol. 22, no. 1, pp. 39--71, 1996.
- [11] J. Lafferty, A. McCallum, and F. C. Pereira, ``Conditional random fields: Probabilistic models for segmenting and labeling sequence data," 2001.
- [12] N. Kambhatla, ``Combining lexical, syntactic, and semantic features with maximum entropy models for extracting relations," in *Proceedings of the ACL 2004 on Interactive poster and demonstration sessions*, p. 22, Association for Computational Linguistics, 2004.

- [13] Z. GuoDong, S. Jian, Z. Jie, and Z. Min, "Exploring various knowledge in relation extraction," in *Proceedings of the 43rd annual meeting on association for computational linguistics*, pp. 427--434, Association for Computational Linguistics, 2005.
- [14] J. Jiang and C. Zhai, "A systematic exploration of the feature space for relation extraction.," in *HLT-NAACL*, pp. 113--120, 2007.
- [15] Y. S. Chan and D. Roth, "Exploiting background knowledge for relation extraction," in *Proceedings of the 23rd International Conference on Computational Linguistics*, pp. 152--160, Association for Computational Linguistics, 2010.
- [16] R. C. Bunescu and R. J. Mooney, "A shortest path dependency kernel for relation extraction," in *Proceedings of the conference on Human Language Technology and Empirical Methods in Natural Language Processing*, pp. 724--731, Association for Computational Linguistics, 2005.
- [17] S. Zhao and R. Grishman, "Extracting relations with integrated information using kernel methods," in *Proceedings of the 43rd Annual Meeting on Association for Computational Linguistics*, pp. 419--426, Association for Computational Linguistics, 2005.
- [18] T. Dunning, "Accurate methods for the statistics of surprise and coincidence," *Computational linguistics*, vol. 19, no. 1, pp. 61--74, 1993.
- [19] S. Gupta, A. Nenkova, and D. Jurafsky, "Measuring importance and query relevance in topic-focused multi-document summarization," in *Proceedings of the 45th Annual Meeting of the ACL on Interactive Poster and Demonstration Sessions*, pp. 193--196, Association for Computational Linguistics, 2007.
- [20] S. C. Deerwester, S. T. Dumais, T. K. Landauer, G. W. Furnas, and R. A. Harshman, "Indexing by latent semantic analysis," *JAsIs*, vol. 41, no. 6, pp. 391--407, 1990.
- [21] H. Daumé III and D. Marcu, "Bayesian query-focused summarization," in *Proceedings of the 21st International Conference on Computational Linguistics and the 44th annual meeting of the Association for Computational Linguistics*, pp. 305--312, Association for Computational Linguistics, 2006.
- [22] A. Haghighi and L. Vanderwende, "Exploring content models for multi-document summarization," in *Proceedings of Human Language Technologies: The 2009 Annual Conference of the North American Chapter of the Association for Computational Linguistics*, pp. 362--370, Association for Computational Linguistics, 2009.

- [23] D. Wang, S. Zhu, T. Li, and Y. Gong, "Multi-document summarization using sentence-based topic models," in *Proceedings of the ACL-IJCNLP 2009 Conference Short Papers*, pp. 297--300, Association for Computational Linguistics, 2009.
- [24] A. Celikyilmaz and D. Hakkani-Tur, "A hybrid hierarchical model for multi-document summarization," in *Proceedings of the 48th Annual Meeting of the Association for Computational Linguistics*, pp. 815--824, Association for Computational Linguistics, 2010.
- [25] K. McKeown, J. Klavans, V. Hatzivassiloglou, R. Barzilay, and E. Eskin, "Towards multidocument summarization by reformulation: Progress and prospects," in *AAAI/IAAI*, pp. 453--460, 1999.
- [26] V. Hatzivassiloglou, J. L. Klavans, M. L. Holcombe, R. Barzilay, M.-Y. Kan, and K. McKeown, "Simfinder: A flexible clustering tool for summarization," 2001.
- [27] D. M. Blei, A. Y. Ng, and M. I. Jordan, "Latent dirichlet allocation," *the Journal of machine Learning research*, vol. 3, pp. 993--1022, 2003.
- [28] G. Heinrich, "Parameter estimation for text analysis," tech. rep., Technical report, 2005.
- [29] A. Asuncion, M. Welling, P. Smyth, and Y. W. Teh, "On smoothing and inference for topic models," in *Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence*, pp. 27--34, AUAI Press, 2009.
- [30] A. Smola and S. Narayanamurthy, "An architecture for parallel topic models," *Proceedings of the VLDB Endowment*, vol. 3, no. 1-2, pp. 703--710, 2010.
- [31] J. Varadarajan, R. Emonet, and J.-M. Odobez, "Probabilistic latent sequential motifs: Discovering temporal activity patterns in video scenes," tech. rep., Idiap, 2010.
- [32] L. L. Mølgaard, J. Larsen, and C. Goutte, "Temporal analysis of text data using latent variable models," in *Proceedings of the IEEE International Workshop on Machine Learning for Signal Processing, 2009.*, 2009.
- [33] D. M. Blei and J. D. Lafferty, "Dynamic topic models," in *Proceedings of the 23rd international conference on Machine learning*, pp. 113--120, ACM, 2006.
- [34] J. Chang and D. M. Blei, "Relational topic models for document networks," in *International Conference on Artificial Intelligence and Statistics*, pp. 81--88, 2009.

- [35] S. Gong, "The personalized information retrieval model based on user interest," *Physics Procedia*, vol. 24, pp. 817--821, 2012.
- [36] H. R. Kim and P. K. Chan, "Learning implicit user interest hierarchy for context in personalization," in *Proceedings of the 8th international conference on Intelligent user interfaces*, pp. 101--108, ACM, 2003.
- [37] Y. Li and N. Zhong, "Mining ontology for automatically acquiring web user information needs," *Knowledge and Data Engineering, IEEE Transactions on*, vol. 18, no. 4, pp. 554--568, 2006.
- [38] X. Tao, Y. Li, and N. Zhong, "A personalized ontology model for web information gathering," *Knowledge and Data Engineering, IEEE Transactions on*, vol. 23, no. 4, pp. 496--511, 2011.
- [39] A. Pretschner and S. Gauch, "Ontology based personalized search," in *Tools with Artificial Intelligence, 1999. Proceedings. 11th IEEE International Conference on*, pp. 391--398, IEEE, 1999.
- [40] A. Sieg, B. Mobasher, and R. Burke, "Web search personalization with ontological user profiles," in *Proceedings of the sixteenth ACM conference on Conference on information and knowledge management*, pp. 525--534, ACM, 2007.
- [41] X. Tao, Y. Li, N. Zhong, and R. Nayak, "Ontology mining for personalized web information gathering," in *Web Intelligence, IEEE/WIC/ACM International Conference on*, pp. 351--358, IEEE, 2007.
- [42] J. Trajkova and S. Gauch, "Improving ontology-based user profiles.," in *RIAO*, vol. 2004, pp. 380--390, 2004.
- [43] A. Sieg, B. Mobasher, and R. D. Burke, "Learning ontology-based user profiles: A semantic approach to personalized web search.," *IEEE Intelligent Informatics Bulletin*, vol. 8, no. 1, pp. 7--18, 2007.
- [44] B. Pang and L. Lee, "Opinion mining and sentiment analysis," *Foundations and trends in information retrieval*, vol. 2, no. 1-2, pp. 1--135, 2008.
- [45] M. Taboada, J. Brooke, M. Tofiloski, K. Voll, and M. Stede, "Lexicon-based methods for sentiment analysis," *Computational linguistics*, vol. 37, no. 2, pp. 267--307, 2011.

- [46] M. Taboada, C. Anthony, J. Brooke, K. Dilkina, M. A. Gillies, J. Grieve, M. Hay, P. Larrivee-Woods, G. Lyons, P. McFetridge, *et al.*, ``Thumbs up or thumbs down?," 2007.
- [47] E. Riloff, S. Patwardhan, and J. Wiebe, ``Feature subsumption for opinion analysis," in *Proceedings of the 2006 Conference on Empirical Methods in Natural Language Processing*, pp. 440--448, Association for Computational Linguistics, 2006.
- [48] E. Riloff and J. Wiebe, ``Learning extraction patterns for subjective expressions," in *Proceedings of the 2003 conference on Empirical methods in natural language processing*, pp. 105--112, Association for Computational Linguistics, 2003.
- [49] J. Wiebe, T. Wilson, R. Bruce, M. Bell, and M. Martin, ``Learning subjective language," *Computational linguistics*, vol. 30, no. 3, pp. 277--308, 2004.
- [50] T. Wilson, J. Wiebe, and R. Hwa, ``Recognizing strong and weak opinion clauses," *Computational Intelligence*, vol. 22, no. 2, pp. 73--99, 2006.
- [51] G. A. Miller, R. Beckwith, C. Fellbaum, D. Gross, and K. J. Miller, ``Introduction to wordnet: An on-line lexical database\*," *International journal of lexicography*, vol. 3, no. 4, pp. 235--244, 1990.
- [52] X. Su and T. M. Khoshgoftaar, ``A survey of collaborative filtering techniques," *Advances in artificial intelligence*, vol. 2009, p. 4, 2009.
- [53] Y. Shi, M. Larson, and A. Hanjalic, ``Collaborative filtering beyond the user-item matrix: A survey of the state of the art and future challenges," *ACM Computing Surveys (CSUR)*, vol. 47, no. 1, p. 3, 2014.
- [54] M. Ripeanu, I. Foster, and A. Iamnitchi, ``Mapping the gnutella network: Properties of large-scale peer-to-peer systems and implications for system design," *arXiv preprint cs/0209028*, 2002.
- [55] M. Ripeanu, ``Peer-to-peer architecture case study: Gnutella network," in *Peer-to-Peer Computing, 2001. Proceedings. First International Conference on*, pp. 99--100, IEEE, 2001.
- [56] B. Y. Zhao, J. Kubiatowicz, A. D. Joseph, *et al.*, ``Tapestry: An infrastructure for fault-tolerant wide-area location and routing," 2001.

- [57] A. Rowstron and P. Druschel, "Pastry: Scalable, decentralized object location, and routing for large-scale peer-to-peer systems," in *Middleware 2001*, pp. 329--350, Springer, 2001.
- [58] I. Stoica, R. Morris, D. Karger, M. F. Kaashoek, and H. Balakrishnan, "Chord: A scalable peer-to-peer lookup service for internet applications," *ACM SIGCOMM Computer Communication Review*, vol. 31, no. 4, pp. 149--160, 2001.
- [59] N. S. Good and A. Krekelberg, "Usability and privacy: a study of kazaa p2p file-sharing," in *Proceedings of the SIGCHI conference on Human factors in computing systems*, pp. 137--144, ACM, 2003.
- [60] D. J. Watts and S. H. Strogatz, "Collective dynamics of 'small-world' networks," *nature*, vol. 393, no. 6684, pp. 440--442, 1998.
- [61] D. Tsoumakos and N. Roussopoulos, "Analysis and comparison of p2p search methods," in *Proceedings of the 1st international conference on Scalable information systems*, p. 25, ACM, 2006.
- [62] N. Bisnik and A. Abouzeid, "Modeling and analysis of random walk search algorithms in p2p networks," in *Hot topics in peer-to-peer systems, 2005. HOT-P2P 2005. Second International Workshop on*, pp. 95--103, IEEE, 2005.
- [63] O. Babaoglu, H. Meling, and A. Montresor, "Anthill: A framework for the development of agent-based peer-to-peer systems," in *Distributed Computing Systems, 2002. Proceedings. 22nd International Conference on*, pp. 15--22, IEEE, 2002.
- [64] T. L. Griffiths and M. Steyvers, "Finding scientific topics," *Proceedings of the National Academy of Sciences*, vol. 101, no. suppl 1, pp. 5228--5235, 2004.
- [65] D. Ramage, D. Hall, R. Nallapati, and C. D. Manning, "Labeled lda: A supervised topic model for credit attribution in multi-labeled corpora," in *Proceedings of the 2009 Conference on Empirical Methods in Natural Language Processing: Volume 1-Volume 1*, pp. 248--256, Association for Computational Linguistics, 2009.
- [66] G. Liu, H. Shen, and L. Ward, "An efficient and trustworthy p2p and social network integrated file sharing system," *Computers, IEEE Transactions on*, vol. 64, no. 1, pp. 54--70, 2015.
- [67] M. Yang and Y. Yang, "An efficient hybrid peer-to-peer system for distributed data sharing," *Computers, IEEE Transactions on*, vol. 59, no. 9, pp. 1158--1171, 2010.



## 个人简历、在读期间发表的学术论文与研究成果

### 个人简历:

先毅昆, 男, 1989 年 11 月出生。

2012 年 6 月毕业于同济大学软件学院, 软件工程专业, 获学士学位。

2012 年 9 月入同济大学软件学院, 软件工程专业, 攻读硕士学位。

### 已发表论文:

[1] Yikun Xian, Jie Huang, Yefim Shuf, Gene Fuh, and Zhen Gao. An Approach for In-Database Scoring of R Models on DB2 for z/OS. Rough Sets and Knowledge Technology. Springer International Publishing, 2014. 376-385.

[2] Yikun Xian, Jiangfeng Li, Chenxi Zhang, Zhenyu Liao. Video Highlight Shot Extraction with Time-Sync Comment. ACM MobiHoc 2015 - HotPOST '15.

### 待发表论文:

### 发明专利:

[1] 张晨曦, 先毅昆, 李江峰. 一种用户兴趣获取与传播的方法和装置: 中国, 201410494809.4[P]. 2015.01.07.